

## Подготовка к защите

Шпаргалка к защите и сценарий презентации на 5 минут. ML-часть проекта:  
прогноз входов на станции 1 линии метро СПб

Команда проекта, ML-часть

Октябрь 2026

# Содержание

|                                                                        |           |
|------------------------------------------------------------------------|-----------|
| <b>Шпаргалка к защите</b>                                              | <b>3</b>  |
| <b>Часть 1. Как устроен проект</b>                                     | <b>4</b>  |
| 1. Задача за 30 секунд . . . . .                                       | 4         |
| 2. Данные . . . . .                                                    | 4         |
| 3. Норма . . . . .                                                     | 6         |
| 4. Главная идея: отклонение от нормы держится 2–3 часа . . . . .       | 7         |
| 5. Признаки . . . . .                                                  | 7         |
| 6. Отбор признаков . . . . .                                           | 9         |
| 7. Модель под капотом . . . . .                                        | 10        |
| 8. Интервал и калибровка . . . . .                                     | 12        |
| 9. Честная проверка . . . . .                                          | 13        |
| <b>Часть 2. Эксперименты после финального теста</b>                    | <b>15</b> |
| 10. Стекинг (ансамбль): LightGBM + персистентность + GRU . . . . .     | 15        |
| 11. 15-минутные данные и ранний сигнал . . . . .                       | 18        |
| 12. Результаты одной таблицей . . . . .                                | 19        |
| 13. Слабые места честно и что дальше . . . . .                         | 20        |
| 14. Демо 31.08 по шагам . . . . .                                      | 21        |
| <b>Часть 3. 50 вопросов жюри и короткие ответы</b>                     | <b>23</b> |
| 15. Вопросы и ответы . . . . .                                         | 23        |
| <b>Сценарий презентации на 5 минут</b>                                 | <b>28</b> |
| Слайд 1. Прогноз входов на станции метро на 1–2 часа вперёд . . . . .  | 28        |
| Слайд 2. Проблема: резерв выходит за 15–20 минут . . . . .             | 29        |
| Слайд 3. Данные и ловушки . . . . .                                    | 30        |
| Слайд 4. Главная идея: отклонение от нормы держится 2–3 часа . . . . . | 30        |
| Слайд 5. Как работает модель . . . . .                                 | 31        |
| Слайд 6. Честная проверка . . . . .                                    | 32        |
| Слайд 7. Результат и демо 31.08 (ключевой) . . . . .                   | 33        |
| Слайд 8. Слабые места и что дальше . . . . .                           | 34        |
| Слайд 9. Итог . . . . .                                                | 34        |

## Шпаргалка к защите

**Для кого.** Для автора ML-части. Цель — понять проект насквозь и ответить на любой вопрос жюри.

**Как читать.** Каждый раздел построен одинаково:

- **Простыми словами** — смысл без терминов и зачем это нужно;
- **Подробнее** — то же точно, с формулами и числами;
- **Наш пример** — реальные цифры проекта;
- **Что ответить, если спросят** — короткая формулировка для жюри.

Все цифры взяты из docs/\* .md, docs/report/report .md и reports/. Если цифра приведена без источника, её можно найти в отчёте по названию раздела. В конце — 50 вопросов жюри с короткими ответами.

**Три цифры, которые стоит помнить:**

- **5,51 % против 6,66 %** — ошибка модели против лучшего простого правила на бэкteste (май–август);
- **7,72 % против 9,61 %** — то же на закрытом сентябре, один запуск;
- **+0,05 п. п. в среднем, но +0,56 п. п. в аномальных часах** — выигрыш стекинга у обычной LightGBM; команда включила его в продукт ради аномальных часов и честного интервала, хотя заранее поставленное правило на мае не выполнено.

## Часть 1. Как устроен проект

### 1. Задача за 30 секунд

**Простыми словами.** Метро решает, сколько поездов пустить и когда вывести резервный состав. Для этого нужно знать, сколько людей придёт на станции в ближайшие часы. Мы предсказываем, сколько человек пройдёт через турникеты на вход в каждой станции 1 линии на следующий час и на час после него.

**Подробнее.**

- **Что на выходе** (раз в час, в конце часа): медианный прогноз  $q_{50}$  и интервал  $q_{10}$ – $q_{90}$  («факт попадёт сюда в 80 % случаев»); норма для этого часа; флаг аномалии; три причины прогноза словами для LLM-слоя.
- **По каким объектам:** 18 станций 1 линии (у «Технологического института» нет часовых данных). Внутри модель считает 23 вестибюля, а в контракт прогноз уходит по станциям.
- **Место в системе.** Наша часть — ML. Прогноз идёт симулятору загрузки перегонов, потом рекомендациям по парности и резерву, потом дашборду. Если прогноз ошибается, ошибаются все следующие части.

**Почему горизонт 1–2 часа.**

- По данным организаторов, резервный состав выходит на линию за 15–20 минут, полный оборот «туда–обратно» занимает 99 минут, в резерве 4 состава. Прогноз на 1–2 часа покрывает это время с запасом.
- Дальше ценность прогноза падает: главный сигнал — отклонение от нормы — держится 2–3 часа.
- На втором часе выигрыш от динамики примерно в 1,4 раза меньше, чем на первом.

**Наш пример.** Максимальная парность на 1 линии — 32 пары поездов в час. В сентябре в 08 ч в линию входит 74,7 тыс. человек, а провозная способность  $32 \text{ пар} \times 1\,458 = 46,7$  тыс. на направление (грубая оценка: в данных только входы).

**Что ответить, если спросят.** «Мы прогнозируем входы на станции на 1 и 2 часа вперёд, потому что резерв выходит за 15–20 минут, а отклонение от нормы живёт 2–3 часа. Дальше прогноз уже мало что добавляет».

### 2. Данные

**Простыми словами.** Организаторы дали выгрузку турникетов: сколько человек вошло через каждый вестибюль в каждый час с января по сентябрь 2026. Пока этих данных не было, мы отлаживали весь конвейер на открытых данных метро другого города — загрузку, очистку, контракт, разведочный анализ. Потом всё переехало на данные СПб.

**Подробнее — что дали организаторы.**

| Файл                                      | Что внутри                                            | Кто использует          |
|-------------------------------------------|-------------------------------------------------------|-------------------------|
| Пассажиропоток 2026<br>Линия 1            | почасовые входы по 23 вестибюлям,<br>01.01–30.09.2026 | ML, основной источник   |
| Входные потоки по 15<br>минут             | февраль, май, июль, сентябрь, 24 вестибюля            | ML, этап 6 и стекинг    |
| График движения, парность,<br>вместимость | интервалы, пары по часам, 1 458 человек на<br>состав  | рекомендации, симулятор |
| Пример остановки<br>обслуживания          | инцидент 31.08, 07:50–10:31, «Чернышевская»           | разметка и демо         |

| Файл       | Что внутри                    | Кто использует |
|------------|-------------------------------|----------------|
| Форма МО-1 | выполнение графика, 3 периода | экономика      |

### Наш пример (цифры).

- После очистки: 23 вестибюля × 6 528 ч = **150 144 строки**, 164 876 717 входов, без дубликатов и пропусков.
- В рабочий день на линию в среднем входит 695 тыс. человек. Самый загруженный вестибюль — Девяткино II: 63,0 тыс.
- Контрольная сумма: сумма входов плюс 418 входов отброшенной метки совпадает со строкой итога файла (164 877 135).

**Какие ловушки нашли в данных СПб.** Каждая искажила бы признаки или метрики, если бы её не заметили.

| Ловушка                                                                                                       | Как нашли                                     | Что сделали                                                                                                                                              |
|---------------------------------------------------------------------------------------------------------------|-----------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Служебные строки: «Сводка» сверху и итог снизу                                                                | при первом чтении                             | обрезали; итог и «Сводку» используем как контрольные суммы                                                                                               |
| Дата — текст «ДД.ММ.ГГГГ ЧЧ», строки отсортированы как строки: сначала первое число каждого месяца            | порядок строк не совпадал со временем         | строгий разбор формата, сортировка по времени; проверка: «08 ч / 12 ч» > 1,2 ровно в рабочие дни, при перепутанных день/месяц не сходятся 42 из 108 дней |
| <b>Часы 00–02 подписаны датой прошедших суток:</b> «27.06 01» — это 28.06 01:00                               | три признака (ниже)                           | перевели метки в реальное время; особых ночей стало 4 вместо 7                                                                                           |
| Режимы вестибюлей: Ленинский пр.-2 работает 06–21, пл. Ленина-2 — 05–22                                       | доля дней с входом по часам                   | флаг «вестибюль закрыт»                                                                                                                                  |
| Инцидент 31.08                                                                                                | материалы организаторов и данные              | флаг на всей линии, 07–11 ч                                                                                                                              |
| Особые ночи: метро работало, когда обычно закрыто (Новый год, Рождество, 29→30.05, «Алые паруса»)             | ненулевые входы в 01–04 ч                     | внесены в справочник событий                                                                                                                             |
| <b>Частичные закрытия входа в пик:</b> Балтийская 08:15–09:15 (до ~19.03), Нарвская 08:15–09:00 (18.06–28.08) | 15-минутные данные; часовые флаги их не видят | флаг <code>is_slot_closed</code> ; «×2,69 на Нарвской» 31.08 — в основном конец этого режима                                                             |
| Два источника: 15-минутный выше часового на 1,15 %                                                            | сверка «сумма 4 четвертей = час»              | истина — часовой файл, 15-минутный сигнал делим на поправку <code>s_v</code>                                                                             |

**Как нашли сдвиг часов 00–02** (самая коварная ловушка — данные выглядели правильными):

- вход в 00 ч по меткам пятницы и субботы выше остальных дней: 1 736 и 1 887 против 976–1 180;
- аномалия часа «D 00» связана с аномалией «D 23» на 0,76 и с «D-1 23» только на 0,35;
- ночь «Алых парусов» непрерывна только при сдвиге: 8,6, 13,0, 5,6, 4,9 и 3,8 тыс. входов в 00–04 ч.

После исправления очистку перезапустили, и все выводы посчитаны уже на исправленных данных.

**Что это говорит о нашей работе.** Мы не верим выгрузке на слово: сверяем контрольные суммы, проверяем гипотезы на данных, находим и исправляем собственные ошибки и пересчитываем всё заново.

**Какие ещё сервисы использовали** (модули `external_data`, их делал Денис; в ML-часть подключены через `src/external_adapter.py`):

- **Погода.** Open-Meteo — исторический прогноз осадков для обучения. Яндекс Погода — источник того же признака в «боевом» режиме: часы сдвигаются на +1 ч, потому что Open-Meteo метит час концом, а Яндекс — началом. Нет ключа или ошибка API — откат на Open-Meteo с предупреждением.
- **Календарь.** `isdayoff.ru` — тип дня с переносами; названия праздников — из `holidays.RU`.
- **События и новости.** Модуль принимает тексты (в том числе из Telegram) и извлекает события через YandexGPT или OpenRouter; геокодер Яндекса привязывает событие к ближайшей станции.
- **Поезда.** Яндекс Расписания — прибытия на 4 вокзала.

Честно: события и поезда идут только в `explanations[ ].context` для LLM-слоя. В модель они не подаются, потому что она на них не обучена. Живого потока данных пока нет: «сейчас» работает только в тестах.

**Что ответить, если спросят.**

- «Откуда данные?» — «Выгрузка турникетов 1 линии за 9 месяцев от организаторов, плюс календарь, погода и справочник событий. До их получения отлаживали конвейер на открытых данных метро другого города».
- «Какие проблемы были в данных?» — «Сдвиг подписи часов 00–02, перепутанный порядок дат, режимы закрытия вестибюлей, инцидент и частичные закрытия входа в пик. Каждую нашли проверкой и учли флагами».

### 3. Норма

**Простыми словами.** Норма — это «сколько обычно входит в этот вестибюль в этот час в этот день недели». Если во вторник в 08:00 обычно заходит 3 000 человек, то 3 000 — это норма. Всё интересное — в отклонении от неё.

**Подробнее.**

- **b4 (основная норма)** — медиана того же вестибюля, часа и дня недели по 4 последним обычным таким же суткам (поиск до 8 недель назад). В историю не идут праздники, события, 1–11 января и часы с флагами. Только прошлое.
- **Праздник или нерабочий будний день** — норма по 4 последним обычным воскресеньям: форма потока будних праздников совпадает с воскресной (корреляция 0,994), а уровень на 36–47 % ниже будней.
- **Поправка на уровень** — медиана суточного отношения «факт / норма» по 7 последним обычным суткам. Итоговая опорная норма модели:  $f\_ref = b4 \times \text{уровень}$ .

**Почему медиана, а не среднее.** Один необычный день — с закрытием или дождём — не сдвигает медиану, а среднее сдвигает.

**Почему 4 недели, а не 8.** Длинная норма сильнее отстаёт от тренда: WAPE 8,97 % против 7,59 %.

**Почему по дню недели, а не по типу дня.** Понедельник на 3,1 % ниже вторника–четверга, пятница на 1,4 % выше. Разброс ( $p95 | r - 1 |$ ) при норме по дню недели 22,5 %, при норме по типу дня 25,7 %.

**Почему нужна поправка на уровень.** Норма смотрит на прошлые недели, а поток меняется: летом падает, в сентябре скачет вверх. Около 40 % связи нашего главного признака с целью

— просто общий уровень месяца. Уровень закрывает это отставание. В июле он около 0,94, 10 сентября — 1,13. Сама по себе поправка снижает WAPE нормы с 7,59 до 6,83 %.

**Наш пример.** 23.02 (праздник) в 08 ч у Девяткино II норма по воскресеньям — 2 674 при факте 2 740. Понедельничная норма была бы 10 084 — ошибка почти в четыре раза.

**Что ответить, если спросят.** «Норма — медиана того же часа в 4 последних таких же днях. Медиана устойчива к необычным дням. Поправка на уровень закрывает отставание нормы от тренда: без неё в сентябре, когда поток вырос на 13,5 %, норма сильно занижала бы».

#### 4. Главная идея: отклонение от нормы держится 2–3 часа

**Простыми словами.** Если сегодня в 08:00 людей вошло на 30 % больше обычного, то вероятнее всего и в 09:00, и в 10:00 их тоже будет больше обычного. «Сегодня не как всегда» — это не случайный шум, а состояние дня: ливень, мероприятие, каникулы, сбой на соседней линии. Поэтому по последним часам можно судить о ближайших.

**Подробнее — откуда это узнали на разведочном анализе.**

- Отклонение  $r$  = факт / норма. Корреляция логарифма  $r$  с лагом 1 / 2 / 3 часа — медиана 0,72 / 0,59 / 0,44.
- После часа, в котором  $r > 1,15$ , выше 1,15 остаётся 50 % следующих часов (в среднем без условия — 11 %). Через два часа — 44 %.
- Утро подсказывает вечер: накопленное с открытия отклонение до 09 ч связано с  $r$  в 17–18 ч того же дня (корреляция Спирмена 0,48).
- Линия задаёт фон дня: корреляция  $r$  вестибюля с  $r$  всей линии 0,62, с соседними станциями 0,45.

**Наш пример (простые прогнозы, WAPE).** Одна лишь норма  $b$  ошибается на 8,53 %. «Норма  $\times r(t)$ » — норма, умноженная на отклонение последнего часа, — ошибается на 6,74 %, на 1,79 п. п. меньше (ДИ 1,13...2,54). На втором часе выигрыш в 1,4 раза меньше — отклонение затухает.

**Что ответить, если спросят.** «Главный сигнал — отклонение от нормы, оно держится 2–3 часа. На разведочном анализе: корреляция с лагом 1 час — 0,72, 2 часа — 0,59, 3 часа — 0,44; после часа с отклонением больше 15 % такое же отклонение остаётся в половине следующих часов против 11 % в среднем. Простое правило „норма  $\times$  текущее отклонение“ уже снижает ошибку с 8,5 до 6,7 %».

#### 5. Признаки

**Простыми словами.** В данных всего три колонки: вестибюль, час, входы. Всё остальное мы придумываем: что было в последний час, что было вчера, что творится у соседей и на всей линии, какой сегодня день, что с погодой. Признак — это число, которое модель получает на вход, чтобы угадать будущее.

**Подробнее — как придумывали.** Список из 56 кандидатов сложился из пяти идей:

- **динамика** — как поток отличается от нормы прямо сейчас и как менялся;
- **кросс** — что происходит у соседей и на всей линии;
- **«вчера»** — отклонение в тот же час вчера и каким был вчерашний день;
- **календарь** — день недели, праздник;
- **погода** — дождь по прогнозу.

Все признаки считаются только по данным до конца часа  $t$ , когда прогноз делается. Признаков месяца и даты нет: в тестовом месяце они принимают значения, которых модель не видела.

**Все 26 признаков финальной модели одной фразой** ( $r$  = факт / норма;  $f_{ref}$  — норма с поправкой на уровень):

| Имя в коде       | Что это простыми словами                                        |
|------------------|-----------------------------------------------------------------|
| vestibule        | какой именно вход — у каждого свой характер                     |
| station_group    | тип станции: спальная конечная, центр и вокзалы, прочая         |
| hour_tau         | на какой час прогноз (сутки метро идут от 05 до 00)             |
| dow_tau          | какой день недели                                               |
| day_type_tau     | рабочий, суббота, воскресенье или праздник                      |
| h                | на сколько часов вперёд прогноз — 1 или 2                       |
| b4_tau           | норма на этот час                                               |
| level            | на сколько последняя неделя выше или ниже нормы                 |
| y_t              | сколько вошло в последний закрытый час                          |
| y_t1             | сколько вошло за час до него                                    |
| y_tau24          | сколько входило вчера в тот же час                              |
| y_tau168         | сколько входило неделю назад в тот же час                       |
| r_t              | насколько последний час отличается от нормы                     |
| ewm_r_2h         | устойчивое отклонение за последние ~2 часа (сглаженное)         |
| ewm_r_6h         | то же за ~6 часов                                               |
| cum_ratio        | на сколько процентов с открытия вошло больше обычного           |
| ratio_168        | последний час против того же часа неделю назад                  |
| r_line           | отклонение от нормы всей линии — фон дня                        |
| ewm_r_line_2h    | сглаженное отклонение линии за ~2 часа                          |
| r_neighbors      | отклонение соседних станций ( $\pm 2$ по линии) — местная часть |
| r_twin           | отклонение второго вестибюля той же станции                     |
| share_dev        | доля вестибюля в линии против обычной: «перетекает ли поток»    |
| r_yday           | отклонение в тот же час вчера                                   |
| cum_ratio_yday   | каким был вчерашний день целиком                                |
| fc_precip_tau    | идёт ли дождь ( $\geq 0,5$ мм/ч) по прогнозу на этот час        |
| fc_precip_3h_tau | сколько осадков по прогнозу за три часа до этого часа           |

Группы: база — 12, ядро динамики — 5, кросс — 5, «вчера» — 2, погода — 2.

#### Что значат слова:

- **Сглаженное (экспоненциальное) среднее** — среднее, в котором недавние часы весят больше; вес старых падает вдвое за «полупериод» (2 или 6 часов). Даёт устойчивое «сегодня выше нормы» без часового шума.
- **Кросс-признаки** — отклонения не своего вестибюля, а соседей и всей линии. Линия задаёт общий фон дня, соседи добавляют местную часть.
- **Динамика** — всё, что описывает недавнее поведение потока.

**Какие признаки модель использует сильнее всего** (по важности gain):  $r$  линии — 17 %,  $r$  того же часа вчера — 13 %,  $r(t)$  — 12 %, вестибюль — 9 %, норма  $b4$  — 8 %, уровень — 5 %.

**Что ответить, если спросят.** «У нас три колонки, значит, всё держится на признаках. Мы собрали 56 кандидатов по пяти идеям, проверили их статистикой и абляцией и оставили 26. Главные — отклонение линии, отклонение вчера и отклонение последнего часа. Все признаки считаются только по данным до момента прогноза».



## 6. Отбор признаков

**Простыми словами.** Из 56 кандидатов не все полезны: часть просто дублирует друг друга, часть — шум. Мы проверяли каждого честным статистическим способом, а потом группами добавляли в модель и смотрели, падает ли ошибка.

**Подробнее — как проверяли каждого кандидата** (на двух горизонтах, итого 112 проверок):

1. **Сравнение внутри слота «вестибюль × час».** Так суточный профиль и размер вестибюля не создают ложной связи: в 08 ч и поток, и почти любой признак большие. Это стратифицированный Спирмен.
2. **Доверительный интервал блочным бутстрепом по дням.** Перевыбираем целые дни, а не часы: часы одного дня зависимы, и обычный бутстреп занизил бы интервал.
3. **p-value перестановками.** Переставляем целые дни внутри «месяц × рабочий / нерабочий»: зависимость внутри дня и сезонность остаются, рвётся только связь признака с целью.
4. **Поправка Бенджамини–Хохберга** на все 112 тестов: при стольких проверках часть «значимых» была бы случайной.
5. **Стабильность** — знак эффекта совпадает минимум в 75 % месяцев.
6. **Дубли** — если два признака связаны сильнее 0,95, оставляем более сильный.
7. **Польза для прогноза ( $\Delta WAPE$ ).** Апрель–август, сентябрь не видим.

**Контрольный шум.** В список положили случайный признак. Он не прошёл отбор: p после поправки 0,99. Это проверка самой процедуры: на чистом шуме она не находит «значимого».

**Почему поменяли правило.**

- **Первое правило** сравнивало эффект признака с шумом слота ( $p80 |r - 1| = 11,4 \%$ ): эффект меньше шума — отбросить. Под него попали почти все признаки динамики.
- **В чём была ошибка.** Шум слота — это разброс одного наблюдения вокруг нормы. Эффект признака — это систематический сдвиг. Признак, который сдвигает прогноз всего на 3 %, всё равно уменьшает ошибку, если сдвигает в нужную сторону в большинстве случаев. Сравнивать эти величины нельзя.
- **Новое правило.** Значимый признак с  $\Delta WAPE > 0$  и интервалом выше нуля получает вердикт «проверить в абляции». Сменились 32 вердикта. Итог: на  $t+1$  — 9 «брать», 19 «в абляцию», 28 «отбросить»; на  $t+2$  — 8 / 19 / 29.

**Что такое абляция.** «Абляция» — по-русски «отрезание»: проверяем пользу части модели, добавляя группы признаков по одной (или убирая по одной) и измеряя, как меняется ошибка. Группа остаётся, если средний выигрыш  $> 0$  и он положителен минимум в 3 фолдах из 4: так группа, которая случайно помогла в одном месяце, не пройдёт.

**Наш пример — таблица абляции** ( $WAPE$ , 4 фолда; выигрыш —  $\Delta WAPE$  к предыдущему шагу, п. п.):

| Шаг                    | WAPE          | Выигрыш [95 % ДИ]    | Фолдов с |           |
|------------------------|---------------|----------------------|----------|-----------|
|                        |               |                      | пользой  | Решение   |
| база (без динамики)    | 6,64 %        | —                    | —        | —         |
| + ядро динамики        | 5,85 %        | +0,80 [+0,63; +0,98] | 4 из 4   | оставлена |
| + кросс                | 5,66 %        | +0,18 [+0,13; +0,24] | 4 из 4   | оставлена |
| + скорость и ускорение | 5,67 %        | -0,00 [-0,02; +0,01] | 2 из 4   | отброшена |
| + вчера                | 5,54 %        | +0,13 [+0,09; +0,17] | 4 из 4   | оставлена |
| + погода               | <b>5,51 %</b> | +0,03 [+0,01; +0,05] | 4 из 4   | оставлена |
| + особые дни           | 5,49 %        | +0,02 [-0,01; +0,05] | 1 из 4   | отброшена |

**Почему скорость и ускорение отбросили.** Это приросты потока за 1–3 часа и изменение отклонения. По отдельности они выглядели полезными (+0,06...+0,18 п. п.), но всё, что в них есть, уже несёт ядро динамики: поверх него они дают –0,00 п. п., интервал вокруг нуля.

**Что показали другие проверки:**

- **База без динамики** на уровне простого правила (6,64 % против 6,66 %). Динамика — главный выигрыш.
- **Особые дни** отброшены: в мае в обучении до 23.04 не было ни одного сокращённого дня, и признак не мог ничему научить. Вернуть группу можно, когда в обучении будет 4 таких дня.
- **«Минус одна группа»** от финального набора: без «кросс» модель теряет 0,13 п. п., без «вчера» — 0,14, без ядра — 0,03 (оно дублируется г линией и г вчера), без погоды — 0,03. Все группы нужны.
- **Погода** прошла на грани: дождь снижает вход на 4,5 %, но в июле её выигрыш всего +0,0004 п. п.

**Что ответить, если спросят.** «Мы проверили 56 кандидатов строгой процедурой: перестановки целых дней, поправка на множественные проверки, контрольный шум. Один раз пересмотрели правило, когда поняли, что сравнивали несопоставимые величины. Окончательное решение принимала абляция на модели: группы добавляли по одной, оставляли тех, кто помогает минимум в 3 фолдах из 4. Скорость и ускорение отбросили: ничего не добавляют поверх динамики».

## 7. Модель под капотом

**Простыми словами.** Модель — это набор простых «если... то...» правил, собранных в сотни маленьких деревьев. Каждое следующее дерево исправляет ошибки предыдущих. На входе — 26 признаков, на выходе — «насколько этот час будет отличаться от нормы». Это и называется градиентным бустингом. Мы обучаем три такие модели: одна выдаёт медиану («скорее всего будет столько»), две другие — нижнюю и верхнюю границу («с вероятностью 10 % будет меньше / больше»).

**Подробнее.**

- **Дерево** — цепочка вопросов: «час = 8? отклонение линии < 0,8? вестибюль = Девяткино II?» — в конце листа число. Одно дерево слабое. **Бустинг** строит их по очереди: каждое учится на остатках предыдущих.
- **LightGBM** — быстрая реализация бустинга. Нам подходит тем, что умеет работать с пропусками (отклонение не определено ночью), с категориями (вестибюль, группа станций, тип дня) и учится за секунды — а мы запускали абляцию много раз.
- **Квантильная регрессия.** Обычная регрессия минимизирует квадрат ошибки и даёт среднее. Мы минимизируем «pinball»: ошибку, у которой недооценка и переоценка штрафуются по-разному:

$$L = \max(\alpha \cdot (y - q), (\alpha - 1) \cdot (y - q)).$$

При  $\alpha = 0,5$  это половина абсолютной ошибки — то есть медиана. При  $\alpha = 0,9$  недооценка штрафуются в 9 раз сильнее переоценки — модель учит верхнюю границу. Поэтому три модели:  $\alpha = 0,1 / 0,5 / 0,9$ . После предсказания квантили сортируются, чтобы  $q_{10} \leq q_{50} \leq q_{90}$ .

- **Зачем квантили, а не «среднее  $\pm$  разброс».** Отклонения несимметричны: провалы бывают глубже всплесков, и наоборот — в зависимости от часа и станции. Квантили не требуют предположения о форме распределения.

#### Почему цель — отклонение от нормы, а не сам поток.

- Модель предсказывает  $z = \log((y + 1) / (f_{\text{ref}} + 1))$ : логарифм отношения факта к норме. Единицы защищают от нуля в часы с малым потоком. Обратно:  $\hat{y} = (f_{\text{ref}} + 1) \cdot e^z - 1$ .
- **Зачем.** Отношение снимает с модели две трудные и уже известные вещи: суточный профиль (утром и вечером потока в разы больше) и разницу масштабов вестибюлей (у Десяткино II до 11 тыс. входов в час, у малых — сотни). Остаётся то, что действительно надо угадать: «насколько сегодня не как обычно».
- **Проверили альтернативу  $\log(1 + y)$ :** отношение лучше — 5,49 % против 5,76 % (+0,27 п. п. [+0,20; +0,32]).
- Если норма меньше одного входа, все квантили равны норме: почти пустой час мы прогнозировать не берёмся.

**Веса строк.** Каждая строка учится с весом  $f_{\text{ref}}$ . Метрика WAPE взвешена потоком: ошибка в час пик на большом вестибюле важнее, чем ночью на малом. Без весов цель-отношение учила бы относительную ошибку, и малые вестибюли и крайние часы (05, 23, 00) тянули бы модель на себя.

**Параметры** — умеренные значения по умолчанию, без подбора: шаг 0,05, 31 лист, лист не меньше 200 строк, до 3 000 деревьев с ранней остановкой (100 итераций без улучшения). Число деревьев на практике от 94 (май, q50) до 1 400 (июль).

#### Почему LightGBM, а не нейросеть и не линейная модель.

- **Нейросеть.** Данных 9 месяцев; нейросети и графовые модели требуют больше. Исходное ТЗ сознательно их исключало. Позже мы всё же проверили GRU внутри стекинга (раздел 10): сама по себе она слабее — 7,96 % против 7,13 %.
- **Линейная квантильная регрессия** проигрывает всего на 0,19 п. п.: главный сигнал почти линейен. Но бустинг выигрывает на взаимодействиях «час  $\times$  вестибюль  $\times$  текущее отклонение», а в сентябре интервал линейной модели заметно уже: покрытие 64,4 % против 71,7 %.
- **CatBoost и XGBoost** в тех же условиях чуть хуже; ансамбль LightGBM + CatBoost не отличим от LightGBM.

**Наш пример — сравнение моделей** (4 фолда, май–август, те же признаки, цель, веса и калибровка):

| Модель                         | WAPE          | Разница с LightGBM, п. п. [ДИ] | Вывод                            |
|--------------------------------|---------------|--------------------------------|----------------------------------|
| <b>LightGBM (заморожена)</b>   | <b>5,51 %</b> | —                              | официальная                      |
| Линейная квантильная регрессия | 5,70 %        | −0,19 [−0,28; −0,10]           | хуже                             |
| CatBoost                       | 5,56 %        | −0,05 [−0,09; −0,02]           | хуже                             |
| XGBoost                        | 5,61 %        | −0,10 [−0,14; −0,06]           | хуже                             |
| LightGBM + CatBoost            | 5,50 %        | +0,01 [−0,01; +0,03]           | не отличима, учится вдвое дольше |

**Что ответить, если спросят.** «Три квантильных бустера LightGBM на 26 признаках. Учим не сам поток, а отклонение от нормы: так модель не тратит силы на суточный профиль. LightGBM выбрана, потому что данные табличные, пропуски и категории обрабатываются

нативно. Мы сравнили её с линейной моделью, CatBoost, XGBoost и ансамблем в тех же условиях — лучше никто не оказался».

## 8. Интервал и калибровка

**Простыми словами.** Помимо «скорее всего будет 7 178» мы говорим: «с вероятностью 80 % будет от 6 910 до 7 552». Это интервал  $q_{10}$ – $q_{90}$ . Хороший интервал честен: если обещает 80 %, то факт попадает в него в 80 % случаев. Сырой интервал модели оказался слишком узким, поэтому мы его «калибруем».

### Подробнее.

- **$q_{10}$ – $q_{90}$**  — нижняя и верхняя границы. Между ними должно быть 80 % фактов (покрытие 80 %).
- **Почему сырой интервал узкий.** На обучающих строках модель ошибается меньше, чем на новых. Покрытие сырых квантилей на бэкteste — 73,4 % вместо 80 %.
- **Конформная калибровка (CQR) простыми словами.** Берём модель, которая не видела последние 4 недели обучения, и смотрим, насколько она на них промахивается за границы. Эти промахи — честная оценка того, насколько надо раздвинуть интервал. Нижнюю и верхнюю границы раздвигаем отдельно (поправка асимметричная). Берём чуть более высокий квантиль промахов с поправкой на конечность выборки (множитель  $1 + 1/n$ ), чтобы гарантия не была слишком оптимистичной.
- **Окна внутри обучения.**  $C$  — последние 28 суток (калибровка),  $E$  — последние 14 суток (ранняя остановка),  $E \subset C$ . Тест в этих расчётах не участвует.
  1. Отложенная модель учится на обучении без  $C$ ; число деревьев — по ранней остановке на  $E$ .
  2. Она прогнозирует  $C$ , которого не видела; по ошибкам считаются поправки в ячейках «период суток  $\times h$ ».
  3. Итоговая модель учится на всём окне.
- **Зачем так сложно.** Ранняя остановка по тесту — подгонка под тест. Калибровка на тех же данных, на которых модель училась, даёт слишком узкий интервал.
- **Станция.**  $q_{50}$  станции — сумма  $q_{50}$  вестибюлей. Сумма квантилей вестибюлей зависила бы интервал станции: вестибюли не ошибаются в одну сторону одновременно. Поэтому интервал станции —  $q_{50} \times$  квантили отношения «факт /  $q_{50}$ » по ячейке «группа  $\times$  период  $\times h$ », посчитанные на прогнозах отложенной модели в окне  $C$ .

### Наш пример.

- Покрытие на бэкteste: 73,4 % сырое → **80,3 %** после поправки (по фолдам 77,4–82,8 %).
- В сентябре: 67,9 % → **71,7 %**. До 80 % не дотянули: поправка подбиралась на 28.07–24.08, а в сентябре другой уровень (ступенька +13,5 %).
- Pinball, нормированный на средний поток: 1,83 % у модели против 2,27 % у лучшего простого правила.

**Что ответить, если спросят.** «Сырой интервал покрывал 73 % вместо 80 %. Мы откалибровали его по ошибкам модели, которая не видела последние 4 недели обучения — это конформная поправка. Покрытие стало 80,3 %. В сентябре на сдвиге уровня — 71,7 %: честно записали как ограничение и предложили скользящую калибровку».

## 9. Честная проверка

**Простыми словами.** Оценка честна, только если модель проверяют на данных, которые она не видела, и притом в том же порядке, в каком будет жить в реальности: учимся на прошлом, проверяем на будущем. Самый коварный враг — утечка: когда модель случайно «подглядывает» в будущее.

**Подробнее — бэктекст.**

- **Фолды.** Тестовые месяцы — май, июнь, июль, август. Для каждого модель обучается заново на всей истории до него. Окно расширяется: данных мало, и ранние месяцы терять нельзя.
- **Зазор 7 суток** между обучением и тестом: признаки смотрят назад до 168 часов, и без зазора последние дни обучения и первые дни теста были бы почти одним и тем же.
- **Почему не случайное разбиение (k-fold).** Модель обучалась бы на будущем и проверялась на прошлом, соседние часы одного дня попадали бы и в обучение, и в тест.

| Фолд      | Обучение (сутки метро) | Тест                    |
|-----------|------------------------|-------------------------|
| май       | 09.02 – 23.04          | 01.05 – 31.05           |
| июнь      | 09.02 – 24.05          | 01.06 – 30.06           |
| июль      | 09.02 – 23.06          | 01.07 – 31.07           |
| август    | 09.02 – 24.07          | 01.08 – 31.08           |
| финальный | 09.02 – 24.08          | 01.09 – 29.09, один раз |

**Почему сентябрь прятали и открыли один раз.**

- Сентябрь — единственная по-настоящему невиданная проверка, причём на сдвиге: учебный год и ступенька +13,5 %.
- Без флага `--final` поток сентября превращается в пропуск ещё до расчёта нормы и входов. Так сентябрь не видит ни один код: ни отбор признаков, ни бейзлайны, ни абляция. Тест это проверяет.
- Если подправить модель после теста и перезапустить, тест превращается в ещё один фолд для подгонки.

**Заморозка с хэшами.**

1. Всё, что определяет модель, записано в `reports/backtest/model_final.json`: признаки, цель, параметры, окна, решение по смеси, правило флага, пороги аномалии без сентября.
2. В файле два вида хэшей SHA-256: конфигурации (2152d675...) и пяти файлов кода (`features.py`, `model.py`, `baseline.py`, `backtest.py`, `eda_spb.py`).
3. Коммит с тегом `freeze-before-final`.
4. Команда `--final` перед запуском пересчитывает хэши и останавливается при расхождении. Повторно тоже не запустится: если файл результатов есть, откажется.
5. До заморозки код теста проверен сухим прогоном на фолде «август».

**Как проверяли отсутствие утечки.**

- **Обрезка данных.** Поток после конца часа `t` удаляется, панель пересобирается — признаки строк с часом `t` должны совпасть полностью. Проверено в трёх точках: 08.07 09:00 (обычный час), 31.08 08:00 (инцидент), 15.06 04:00 (ночь). Тест чувствителен: если подложить признак из часа `t + 1`, он падает.
- **Нет признаков даты и месяца** — проверяется по именам, типам и связи со временем.

- **Режим повтора:** тест подменяет весь поток после момента прогноза шумом, прогноз не меняется.
- **Калибровка не видит тест:** шум или NaN вместо факта теста ничего не меняют.
- **Однажды нашли свою ошибку:** одноимённый признак затёр колонку, по которой считался бейзлайн. Исправили и запретили совпадение имён тестом.

#### **Как читать результаты проверки:**

- **WAPЕ** — суммарная абсолютная ошибка, делённая на суммарный поток. Большие вестибюли в час пик весят больше.
- **$\Delta$ WAPЕ** — разница ошибок двух моделей в процентных пунктах (п. п.). Плюс — наша модель лучше.
- **95 % ДИ** — доверительный интервал блочным бутстрепом по дням: «в 95 % перевыборки разница лежит здесь». Если весь интервал выше нуля — выигрыш не случаен.
- **p Диболда–Мариано** — тест, что две модели точны по-разному; учитывает зависимость ошибок соседних часов.

**Что ответить, если спросят.** «Проверка — бэкtest на четырёх месяцах с расширяющимся окном и неделей зазора, а затем сентябрь, закрытый от любого кода до заморозки. Модель заморожена с хэшами конфигурации и кода, тест запущен один раз, результат записан как есть. Утечку проверяем тестами: если обрезать поток после момента прогноза, признаки не меняются».

## Часть 2. Эксперименты после финального теста

### 10. Стекинг (ансамбль): LightGBM + персистентность + GRU

**Простыми словами.** Представьте трёх прогнозистов и судью. Первый (LightGBM) знает всю историю, но смотрит на данные раз в час. Второй (персистентность) говорит: «следующие полчаса будут такими же необычными, как последние полчаса». Третий (GRU) — нейросеть с памятью: читает поток маленькими 15-минутными шагами за последние 4 часа. Судья (мета-модель) не придумывает свой прогноз, а решает, кому сколько верить, и берёт взвешенное среднее.

**Зачем пробовали.** Организаторы дали 15-минутные данные, а мы до этого прогнозировали час. Хотелось проверить: если смотреть на поток чаще, получится ли прогноз каждые 30 минут на 4 получасовых слота вперёд (горизонты 30 / 60 / 90 / 120 минут) точнее часового?

**Подробнее — постановка.**

- Момент прогноза  $t$  — hh:00 или hh:30. Слот — получасовой интервал  $[t, t+30)$ , ...,  $[t+90, t+120)$ .
- Что известно в момент  $t$ : 15-минутные данные до  $t$ ; часовые данные — до последнего закрытого часа (в hh:30 час hh ещё не закрыт).
- Истина — сумма двух четвертей 15-минутного источника. Норма слота —  $b_4 \times s_v \times$  доля половины часа из профиля (поправка источника  $s_v$  и профиль — только по прошлому). Цель та же, что у часовой модели:  $z = \log((y+1)/(норма+1))$ .

**Базовые модели** (каждая выдаёт  $q_{10}$ ,  $q_{50}$ ,  $q_{90}$  в пространстве  $z$ ):

| Модель                      | Что делает                                                                    | Что видит                     |
|-----------------------------|-------------------------------------------------------------------------------|-------------------------------|
| <b>B1 — LightGBM</b>        | замороженная часовая модель; её прогноз часа умножается на долю половины часа | всю историю в часовом виде    |
| <b>B2 — персистентность</b> | норма слота $\times$ отклонение последних двух четвертей (30 минут)           | последние 30 минут            |
| <b>B3 — GRU</b>             | нейросеть: 16 шагов по 15 минут $\rightarrow$ 4 горизонта $\times$ 3 квантиля | последние 4 часа мелким шагом |

**Что именно делает GRU.**

- **GRU** — рекуррентная нейросеть: читает последовательность шаг за шагом и хранит «память» о прочитанном.
- **На каждом шаге** она получает отклонение четверти от нормы, флаг пропуска (ночь, закрытие), отклонение всей линии и флаг пропуска линии. Кроме того, ей даются эмбединги — «лица» вестибюля, четверти суток, дня недели и типа дня.
- **Выход** — 12 чисел: 4 горизонта  $\times$  3 квантиля. Верхняя и нижняя границы заданы как  $q_{50} \pm \text{softplus}$ , поэтому квантили не пересекаются.
- **Потери** — pinball, взвешенный нормой слота.
- **Обучение:** 3 seed с усреднением; ранняя остановка по последним 7 суткам обучения; стандартизация по обучению; процессор, один поток, прогнозы воспроизводятся побитово. Последовательности не пересекают разрывы между месяцами: окно допустимо, только если оно целиком лежит внутри своего месяца.

**Важно — на чём учится GRU.** GRU обучалась на тех же месяцах, что и вся остальная система (февраль, май, июль), просто видит те же данные мелким 15-минутным шагом. Это **не** «отдельная нейросеть, обученная на 15-минутках сама по себе». Точная схема — расширяющееся окно, как у LightGBM:

| Тестовый месяц | Чему учится GRU      | Чему учится мета-модель       |
|----------------|----------------------|-------------------------------|
| май            | февраль              | (вход — прогнозы вне выборки) |
| июль           | февраль + май        | (вход — прогнозы вне выборки) |
| сентябрь       | февраль + май + июль | веса заморожены на мае и июле |

То есть для каждого тестового месяца GRU видит только предыдущие месяцы, а не «все три сразу».

### Почему GRU, а не одномерная свёртка (1D-CNN).

- Окно короткое (16 шагов), скорость не важна.
- Главное в данных — затухание отклонения: оно держится 2–3 часа, последние четверти весят больше всего. Рекуррентное состояние учит это затухание напрямую.
- Ночные и закрытые четверти GRU обходит через флаги и ворота. Свёртка смешивала бы их с данными на тех же позициях.
- На процессоре GRU детерминирована.

### Мета-модель — «судья».

- **Вход** — только прогнозы вне выборки за май и июль. Февраль в мета-модель не идёт: часовая LightGBM на нём обучалась, и её прогнозы там чересчур хороши — судья научился бы слишком ей верить.
- **Что подбирает.** Веса базовых моделей для каждого горизонта и каждого квантиля: неотрицательные, в сумме 1; подбор по взвешенному pinball на сетке с шагом 0,05.
- **Сложность выбрана перекрёстно:** «обучить на мае → проверить на июле» и наоборот. Рассматривали веса по горизонту, по горизонту × период суток, по горизонту × минута прогноза (:00 / :30). Ни один вариант не лучший в обоих направлениях, поэтому взят простейший — веса по горизонту. Различия были в пятом знаке pinball.
- **Интервал** — конформная поправка по последнему месяцу обучения стекинга.

**Как GRU «сотрудничает» с LightGBM.** Модели не сливаются в одну и не обучаются вместе. Каждая отдельно даёт свой прогноз, а судья смешивает:  $q = w1 \cdot B1 + w2 \cdot B2 + w3 \cdot B3$  отдельно для q10, q50 и q90 в пространстве z, затем квантили сортируются и калибруются. Если вес одной модели равен 1, стекинг в точности равен ей (это проверяет тест).

**Кому судья верит** (веса стекинга, обученного на мае и июле):

| Квантиль   | Модель          | 30 мин      | 60 мин      | 90 мин      | 120 мин     |
|------------|-----------------|-------------|-------------|-------------|-------------|
| q10        | LightGBM        | 0,55        | 0,65        | 0,70        | 0,80        |
| q10        | персистентность | 0,20        | 0,20        | 0,20        | 0,20        |
| q10        | GRU             | 0,25        | 0,15        | 0,10        | 0,00        |
| <b>q50</b> | <b>LightGBM</b> | <b>0,70</b> | <b>0,80</b> | <b>0,90</b> | <b>0,90</b> |
| q50        | персистентность | 0,15        | 0,15        | 0,10        | 0,10        |
| q50        | GRU             | 0,15        | 0,05        | 0,00        | 0,00        |
| q90        | LightGBM        | 0,60        | 0,65        | 0,65        | 0,75        |
| q90        | персистентность | 0,05        | 0,05        | 0,05        | 0,05        |
| <b>q90</b> | <b>GRU</b>      | <b>0,35</b> | <b>0,30</b> | <b>0,30</b> | <b>0,20</b> |

Читать так: медиану в основном даёт LightGBM, и чем дальше горизонт, тем больше ей верят (0,70 → 0,90). GRU нужна прежде всего для верхней границы вилки: вес у q90 — от 0,20 до 0,35.

**Что это дало.** Май и июль вместе, всё вне выборки, 185 119 слотов (WAPЕ получасового слота):



| Модель                | 30 мин        | 60 мин        | 90 мин        | 120 мин       | Все           | Покрытие<br>q10–q90 |
|-----------------------|---------------|---------------|---------------|---------------|---------------|---------------------|
| B1: LightGBM          | 6,92 %        | 7,06 %        | 7,20 %        | 7,37 %        | 7,13 %        | 69,3 %              |
| B2: персистентность   | 8,72 %        | 9,04 %        | 9,40 %        | 9,76 %        | 9,22 %        | 78,3 %              |
| B3: GRU               | 7,33 %        | 7,86 %        | 8,10 %        | 8,59 %        | 7,96 %        | 66,7 %              |
| Простое среднее B1–B3 | 6,98 %        | 7,22 %        | 7,48 %        | 7,78 %        | 7,36 %        | 77,3 %              |
| <b>Стекинг</b>        | <b>6,85 %</b> | <b>6,99 %</b> | <b>7,16 %</b> | <b>7,35 %</b> | <b>7,09 %</b> | <b>78,5 %</b>       |

Выигрыш стекинга у LightGBM (п. п. [95 % ДИ]; лучшая из базовых моделей на каждом горизонте — всегда LightGBM):

|                       | Все слоты            | 30 мин               | 120 мин              | Аномальные часы      |
|-----------------------|----------------------|----------------------|----------------------|----------------------|
| май + июль, основной  | +0,05 [+0,02; +0,08] | +0,06 [+0,02; +0,11] | +0,02 [+0,00; +0,03] | +0,56 [+0,37; +0,75] |
| май (обучен на июле)  | +0,04 [–0,00; +0,10] | +0,06 [–0,00; +0,15] | +0,02 [–0,00; +0,04] | +0,79 [+0,44; +1,06] |
| июль (обучен на мае)  | +0,05 [+0,03; +0,08] | +0,06 [+0,01; +0,11] | +0,01 [–0,01; +0,03] | +0,38 [+0,27; +0,50] |
| сентябрь, один прогон | +0,18 [+0,12; +0,24] | +0,33 [+0,24; +0,43] | +0,06 [+0,03; +0,11] | +0,40 [+0,25; +0,56] |

## Выводы.

- **Сама по себе GRU слабее:** 7,96 % против 7,13 % у LightGBM. Простое среднее хуже LightGBM (7,36 %): две слабые модели тянут его вниз. Судья нужен, чтобы не усреднять вслепую.
- **В среднем выигрыш почти нулевой:** +0,05 п. п. В часы пик разницы нет (+0,00 [–0,02; +0,03]).
- **Польза только в двух местах:**
  - **аномальные часы:** +0,56 п. п. [+0,37; +0,75] — 15-минутные данные видят отклонение раньше, чем оно доходит до часовой модели;
  - **интервал:** покрытие 78,5 % против 69,3 % у LightGBM на слотах (поправка часовой модели откалибрована на часах, а слот шумнее).
- **Цена для слота «120 минут» в :30.** Прогноз часовой модели, сделанный в hh:00, не доходит до часа hh+2, и мы вызываем её на третий час вперёд (h = 3), хотя учили на h = 1, 2. На первых половинах часа это стоит около 0,3 п. п.: 7,33 % против 7,01 % при h = 2.
- **Сентябрь** (не чистая отложенная выборка — его часовые результаты уже известны): стекинг 8,90 % против 9,08 %, на сдвиге уровня выигрыш втрое больше (+0,18 п. п.). Сильнее всего — на 30 минут из :30: 8,38 % против 8,89 %.

**Почему всё-таки включили в продукт — решение команды.** `serve.forecast(now)` по умолчанию отдаёт прогноз стекинга, LightGBM — внутри него и запасным путём (`model="lgbm"`).

- **Довод «против».** В среднем выигрыш мал: +0,05 п. п. Перед экспериментом мы сами поставили правило: подключать, только если стекинг лучше LightGBM и на мае, и на июле с ДИ выше нуля. На мае ДИ [–0,00; +0,10] касается нуля — правило не выполнено.
- **Довод «за».** Продукту важна не средняя цифра. Резерв выводят именно в необычные часы, а там стекинг точнее на 0,56 п. п. [+0,37; +0,75]. Интервал честнее: покрытие 78,5 % против 69,3 % у LightGBM. Для решения о резерве важнее не ошибиться в необычный час и честно показать неопределённость, чем выиграть сотые доли процента в среднем.
- **Компромисс.** Команда осознанно отступила от своего правила. Правило не переписали задним числом: результаты записаны как есть, а решение — продуктовое, с открытым обоснованием.
- **Риски:**

- средний выигрыш может не повториться на новых данных;
  - формат другой: получасовые слоты, горизонты 30–120;
  - стекинг работает только при 15-минутных данных (февраль, май, июль, сентябрь), в 06–00 и в обычные сутки, иначе отвечает LightGBM с пометкой в meta;
  - в мае и июле веса стекинга подобраны на тех же месяцах.
- **Как откатить:** `model="lgbm"`. Решение пересматриваем на новых месяцах данных.

**Что ответить, если спросят.** «Мы проверили, даёт ли прогноз каждые 30 минут выигрыш. Взяли три базовые модели: часовой LightGBM, персистентность и GRU на 15-минутных рядах — все учились на одних и тех же месяцах. Судья-мета-модель взвешивает их прогнозы: медиану в основном даёт LightGBM, GRU нужна для верхней границы. Итог: GRU сама хуже, стекинг лучше LightGBM всего на 0,05 п. п., и только в аномальных часах (+0,56 п. п.) и по интервалу (78,5 против 69 %) выигрыш заметен. На мае средний выигрыш незначим, и наше же правило не выполнено, но команда включила стекинг ради аномальных часов и честного интервала — это осознанный компромисс, а откат — одна настройка `model="lgbm"`».

## 11. 15-минутные данные и ранний сигнал

**Простыми словами.** Часовые данные приходят раз в час. Если в 08:00 что-то случилось, то из часового файла мы узнаем об этом только в 09:00. 15-минутные данные позволяют заметить аномалию уже через полчаса.

**Подробнее.**

- **Данные.** Февраль, май, июль и сентябрь, 276 480 строк (24 вестибюля × 120 суток × 96 слотов), 75 929 175 входов. Подпись времени та же, что в часовом файле: 00:00–02:45 относятся к следующей дате.
- **Сумма 4 четвертей ≠ часу.** Совпадают точно только 1,7 % часов. 15-минутный источник выше часового на 1,15 % (около +10 входов в час на вестибюль), стабильно по месяцам. **Решение (вариант А):** истина — часовой файл, 15-минутный сигнал делится на поправку источника  $s_v$ , посчитанную по 14 прошлым суткам.
- **Профиль внутри часа.** Днём поток почти ровный (неравномерность 5,8 % часа). Резкие часы: открытие (05 ч — 47,9 %), полночь (45,7 %) и утро: в 07 ч поток растёт к концу часа (последняя четверть 31,8 %), в 08 ч убывает.
- **Ранний сигнал.** Частичное отклонение после  $k$  четвертей:  $r_k = \Sigma \text{факта} / (\text{норма} \times s_v \times \text{доля профиля})$ . Экстраполяция  $b4 \cdot r_k$  предсказывает весь час.

**Наш пример (WAPЕ часа к часовому файлу, февраль + май + июль).**

| К какой минуте часа | Прогноз                                       | WAPЕ          |
|---------------------|-----------------------------------------------|---------------|
| 0 (начало часа)     | норма $b4$                                    | 7,02 %        |
| 0                   | лучшее простое правило                        | 6,05 %        |
| 0                   | модель $t+1$ (май, июль)                      | 5,15 %        |
| 15 минут            | экстраполяция $b4 \cdot r1$                   | 7,94 %        |
| <b>30 минут</b>     | <b>экстраполяция <math>b4 \cdot r2</math></b> | <b>4,49 %</b> |
| 45 минут            | $b4 \cdot r3$                                 | 2,76 %        |

Через 15 минут экстраполяция хуже модели: одна волна поезда в четверти часа весит вчетверо больше, чем в часе. Через 30 минут она уже точнее модели на тех же строках: 4,63 % против 5,15 %, разница −0,52 п. п. [−0,86; −0,23].

**Детектор тревог.** Тревога на первом  $k$ , где  $|r_k - 1|$  выше порога  $p95$  группы, умноженного на  $s_k$ ;  $s = 1,40 / 1,10 / 1,05$  на 15 / 30 / 45 минут (по максимуму F1 на феврале, мае и июле, зафиксировано до сентября).

| К минуте                 | 0    | 15   | 30   | 45   | 60   |
|--------------------------|------|------|------|------|------|
| Найдено аномальных часов | 24 % | 43 % | 66 % | 79 % | 92 % |
| Точность тревог          | 31 % | 35 % | 37 % | 40 % | 42 % |
| Найдено, сентябрь        | 55 % | 58 % | 80 % | 89 % | 96 % |

**Зачем это нужно для резерва.** Резервный состав выходит на линию за 15–20 минут. По часовым данным аномалия видна только на 60-й минуте часа, по 15-минутным медиана обнаружения — 30 минут: на полчаса раньше. Этого времени хватает, чтобы решение о резерве успело сработать.

**Цена ранности — ложные тревоги.** Около 60 % ранних тревог ложные: примерно 1,5 на вестибюль в сутки. В сентябре точность выше (72 %), потому что аномалий больше из-за ступеньки уровня.

**Что ответить, если спросят.** «По часовым данным аномалию видно на 60-й минуте, по 15-минутным — на 30-й: к 30-й минуте находим 66 % аномальных часов. Резерв выходит за 15–20 минут, поэтому эти полчаса важны. Платим ложными тревогами: точность около 40 %, и это отдельный вопрос к рекомендациям».

## 12. Результаты одной таблицей

|                                                    | Бэктест, май–август           | Финальный тест, 1–29 сентября |
|----------------------------------------------------|-------------------------------|-------------------------------|
| Норма b (4 недели)                                 | 7,59 %                        | 11,87 %                       |
| Сезонный наивный («как неделю назад»)              | 10,01 %                       | 8,82 %                        |
| <b>Лучшее простое правило «b × уровень × r(t)»</b> | <b>6,66 %</b>                 | <b>9,61 %</b>                 |
| <b>LightGBM, финальная</b>                         | <b>5,51 %</b>                 | <b>7,72 %</b>                 |
| Выигрыш, п. п. [95 % ДИ], p DM                     | +1,16 [+1,02; +1,30], < 0,001 | +1,89 [+1,57; +2,24], < 0,001 |
| Часы пик 07–09 и 17–19: модель / правило           | 4,50 % / 5,74 %               | 7,13 % / 9,11 %               |
| Аномальные часы: модель / правило                  | 17,95 % / 16,43 %             | 13,14 % / 14,16 %             |
| Покрывание интервала q10–q90 (цель 80 %)           | 80,3 %                        | 71,7 %                        |
| WAPE по горизонтам t+1 / t+2                       | 5,33 % / 5,68 %               | 7,23 % / 8,21 %               |

Все цифры — WAPE по всем часам 05–00, среднее по прогнозам на 1 и 2 часа. По фолдам бэктеста: май 6,1 %, июнь 5,6 %, июль 5,2 %, август 5,1 %.

### Что показывает таблица:

- Модель лучше простого правила в каждом месяце бэктеста, в часы пик и во всех группах станций.
- Сентябрь труднее (ступенька уровня +13,5 % и новый учебный год): ошибка модели выросла с 5,51 до 7,72 %, но выигрыш у правила вырос с 1,16 до 1,89 п. п.
- Первые две недели сентября — основная ошибка: 9,77 % против 5,84 % во второй половине месяца, когда норма догнала уровень.
- Сильнее всего выигрыш у «прочих» станций: 8,59 % против 12,28 %. Именно у них ступенька выше всех (+28,3 %, учебный год).
- В аномальных часах на бэкteste модель хуже правила — это слабое место (раздел 13).
- Сезонный наивный в сентябре — второй (8,82 %): неделю назад уже был сентябрьский уровень, а норма за 4 недели его не видит.

### 13. Слабые места честно и что дальше

#### Слабые места.

| Слабость                            | Цифры                                                                                                                   | Что про неё сказать                                                                           |
|-------------------------------------|-------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| Аномальные часы                     | на бэкteste 17,95 % у модели против 16,43 % у правила                                                                   | модель не переносит отклонение целиком вперёд: откат ловит, устойчивый всплеск — хуже         |
| Смесь с правилом                    | аномальные часы улучшались до 16,96 %, но общий WAPE терял 0,06 п. п. при допуске 0,02                                  | не принята, записана в ограничения                                                            |
| Резкий всплеск: «Алые паруса» 27.06 | прогноз линии +14 % к норме, факт +36 %; в таблице особых дней 10,7 % / 12,0 % у модели против 9,6 % / 11,1 % у правила | устойчивый всплеск модель недооценивает                                                       |
| Интервал на сдвиге уровня           | в сентябре 71,7 % вместо 80 %                                                                                           | поправка откалибрована на июле–августе                                                        |
| Флаг аномалии шумный                | бэкtest: precision 0,33, recall 0,30, F1 0,32; сентябрь: 0,49 / 0,66 / 0,56                                             | флаг предсказывает аномалию за 1–2 часа до неё                                                |
| Сам провал и отложенный спрос       | 31.08: провал в 08 ч не предсказан никем; в 10 ч поток +30 % к норме не предсказан                                      | инцидентов такого масштаба в обучении нет                                                     |
| Мало данных                         | 9 месяцев, годовой сезонности нет; праздников в обучении 7, сокращённых дней 3                                          | правило абляции «3 фолда из 4» не видит редкие признаки                                       |
| Гиперпараметры                      | не подбирались                                                                                                          | один набор параметров и один seed                                                             |
| Только входы                        | пересадок и направлений нет                                                                                             | оценка ёмкости линии грубая                                                                   |
| Два источника потока                | 15-минутный выше часового на 1,15 %                                                                                     | если живой поток придёт из 15-минутного источника, входы будут на ~1 % выше, чем при обучении |
| Закрытия входа в пик                | Балтийская, Нарвская                                                                                                    | часовые флаги их не видят, модель учила их как обычные часы                                   |
| Нет живого потока                   | forecast() на сегодня отвечает «вне периода данных»                                                                     | «сейчас» работает только в режиме повтора                                                     |

#### Что дальше.

- **10-минутные данные АСКОП М** — для горизонтов 15–60 минут; контракт уже допускает шаг 15 минут.
- **Скользкая калибровка** интервала по последним 4 неделям перед каждым днём прогноза — закроет недопокрытие на сдвиге.
- **Смесь только для устойчивых отклонений:** вес по длительности отклонения, а не по величине.
- **Особые дни:** вернуть группу признаков, когда в обучении будет не меньше 4 сокращённых дней (следующий — 3.11).
- **Стекинг на большем объёме данных:** в сентябре его выигрыш +0,18 п. п., втрое больше, чем на мае и июле; решение о включении пересмотреть на новых месяцах — если выигрыш исчезнет и в аномальных часах, откатить на LightGBM. Кандидаты в базовые модели — LightGBM на 15-минутных признаках и часовая модель, обученная на третьем часе вперёд.
- **Ансамбль LightGBM + CatBoost:** в сентябре на 0,04 п. п. лучше LightGBM ( $p = 0,056$ ); проверить на новых месяцах.
- **Подбор гиперпараметров** на отложенном окне.

**Что ответить, если спросят.** «Главное слабое место — аномальные часы: модель хуже простого правила на 1,5 п. п., потому что не переносит отклонение целиком. Мы пробовали смесь,

но она портила общую точность. Второе — интервал на сдвиге уровня: 72 % вместо 80 %. Всё это записано в ограничения, есть план: скользящая калибровка и более частые данные».

#### 14. Демо 31.08 по шагам

**Простыми словами.** 31 августа на «Чернышевской» была остановка обслуживания с 07:50 до 10:31. Поток по всей линии обвалился, а потом откатился назад. Мы показываем, как две модели прогнозируют следующий час в 08:59, когда провал уже виден, а откат ещё нет.

##### Шаг за шагом.

1. **Что произошло.** На «Девяткино» в 08 ч вошло 3 969 человек при норме 13 942. Поток упал не только там, где закрывали вход: Девяткино II — 0,21 от нормы, Девяткино I — 0,40, пл. Ленина-1 — 0,62, Чернышевская — 0,64.
2. **Момент прогноза — 08:59.** Данные до конца 08 ч известны. В последний час поток на «Девяткино» на 75 % ниже нормы, вся линия на 25 % ниже нормы. Прогнозируем 09 ч (горизонт 60) и 10 ч (горизонт 120).
3. **Что говорит простое правило** «норма × текущее отклонение»: проваленный час повторится. На «Девяткино» на 09 ч — 2 849 при норме 8 295.
4. **Что говорит модель.** Модель lgbm\_holdout (обучена по 24.08, то есть вне выборки) отвечает 7 178 [6 910; 7 552].
5. **Что было на самом деле:** 8 445. Поток вернулся к норме.
6. **Почему модель права.** Она выучила: крайнее отклонение последнего часа вместе с провалом всей линии не держится. В обучении 31.08 и похожих провалов не было — это не заучивание, а общая закономерность. Топ-3 причины: «в последний час поток на 75 % ниже нормы» (−7 %), «вся линия на 25 % ниже нормы» (−5 %), «поправка на величину нормы» (−3 %).

##### Наш пример — 09:00, горизонт 60 минут, прогноз в 08:59:

| Станция        | Норма  | Простое правило | Модель [q10; q90]           | Факт   |
|----------------|--------|-----------------|-----------------------------|--------|
| Девяткино      | 8 295  | 2 849           | <b>7 178</b> [6 910; 7 552] | 8 445  |
| Площадь Ленина | 2 299  | 1 605           | <b>1 960</b> [1 824; 2 126] | 2 750  |
| Чернышевская   | 846    | 538             | <b>758</b> [705; 822]       | 694    |
| Нарвская       | 957    | 2 577           | <b>1 072</b> [1 000; 1 147] | 1 099  |
| вся линия      | 39 428 | 34 237          | <b>38 081</b>               | 42 467 |

На 10 ч (горизонт 120) у «Девяткино»: норма 5 079, правило 1 718, модель 4 421, факт 6 594; по всей линии — норма 29 470, правило 26 151, модель 28 581, факт 33 019.

##### Что честно признать:

- **Сам провал в 08 ч не предсказывает никто:** прогноз на 08 ч сделан до инцидента, и обе модели дают норму.
- **Факт 8 445 выше интервала модели** [6 910; 7 552]. Модель откатывается к норме, но откат вышел сильнее.
- **Отложенный спрос выше нормы** (10 ч, +30 %) модель не предсказала: подобных случаев в обучении не было.
- **Нарвская** — обратный случай: в 08 ч ×2,7 к норме, правило переносит пик (2 577), модель нет (1 072 при факте 1 099). Но этот пик в основном конец режима закрытия входа 08:15–09:00, а не уход пассажиров с других станций.
- **Флаг аномалии** стоял на всех станциях инцидента — это сигнал диспетчеру ещё до сообщения об остановке.

**Про две версии цифр.** В docs/backtest.md демо посчитано моделью фолда «август» (обучена до 24.07): «Девяткино» 09 ч — 7 545. В режиме повтора (команда `python -m src.serve --now "2026-08-31 08:59"`) отвечает `lgbm_holdout`: 7 178. Это одна и та же конфигурация модели, обученная на разной длине истории; везде выше — режим повтора. Стекинг для 31.08 не отвечает: за август нет 15-минутных данных, поэтому `serve` автоматически отдаёт часовую LightGBM и пишет причину в `meta["fallback"]`.

**Что ответить, если спросят.** «31.08 на „Девяткино“ в 08 ч вошло 3 969 при норме 13 942. В 08:59 мы прогнозируем 09 ч: простое правило переносит провал вперёд и даёт 2 849, наша модель — 7 178 при факте 8 445. Модель поняла, что такой провал не держится: училась без этого дня. Сам провал в 08 ч не предсказывает никто, и откат вышел чуть выше нашего интервала — это мы честно показываем».

## Часть 3. 50 вопросов жюри и короткие ответы

### 15. Вопросы и ответы

#### Данные

**1. Откуда у вас данные?** Организаторы передали почасовые входы по 23 вестибюлям 1 линии за 01.01–30.09.2026 (150 144 строки, 164 876 717 входов) и 15-минутные данные за четыре месяца. Мы добавили календарь (isdayoff.ru), погоду (Open-Meteo) и справочник событий.

**2. Зачем вы использовали открытые данные другого метро?** Пока реальных данных не было, мы на них отладили загрузку, очистку, контракт, разведочный анализ и правила для признаков. Обучение модели и все её цифры — только по СПб.

**3. Хватает ли 9 месяцев данных?** Для часового прогноза с нормой по 4 неделям — да: бэк-тест на четырёх фолдах даёт 5,51 %. Но годовой сезонности нет, праздников в обучении 7, сокращённых дней 3: это записано в ограничения.

**4. Какие ловушки нашли в данных?** Дата в виде текста с неверным порядком строк; часы 00–02 подписаны датой прошедших суток; режимы закрытия вестибюлей; инцидент 31.08; особые ночи; частичные закрытия входа в пик на Балтийской и Нарвской; расхождение двух источников на 1,15 %. Каждую нашли проверкой и учли флагом или поправкой.

**5. Как вы поняли, что часы 00–02 сдвинуты?** Три признака: вход в 00 ч выше всего у меток пятницы и субботы (1 736 и 1 887 против 976–1 180); аномалия «D 00» связана с «D 23» на 0,76 и с «D–1 23» на 0,35; ночь «Алых парусов» непрерывна только при сдвиге. После исправления всё пересчитано.

**6. Почему вы исключаете часы с флагами?** Ноль в закрытый час — это расписание, а не спрос; провал при инциденте научил бы модель, что такое бывает в обычный понедельник. Исключаются только цели и метрики, а входы (наблюдённый поток) берутся как есть, включая час инцидента: в момент прогноза это реальные данные. Из 125 120 строк в часы работы метро исключено 1 730, то есть 1,4 %.

**7. Что такое «сутки метро»?** Сутки с 05:00 до 04:59 следующего дня. Час 00 относится к прошедшим суткам. Так устроена выгрузка, и так считаются нормы и «вчера».

**8. Почему только входы?** В данных нет выходов, пересадок и направлений. Поэтому оценка ёмкости линии грубая: нагрузка самого загруженного перегона не равна сумме входов.

**9. Что с «Технологическим институтом»?** В часовых данных его нет, в 15-минутных есть (около 10 тыс. входов в сутки). Модель его не прогнозирует; в профиль внутри часа он включён.

#### Модель

**10. Что такое норма и почему медиана?** Норма — медиана того же вестибюля, часа и дня недели по 4 последним обычным таким же дням. Медиана устойчива к необычным дням (закрытие, дождь), среднее — нет. Для праздников берётся профиль воскресенья.

**11. Почему вы предсказываете отклонение от нормы, а не сам поток?** Так модель не тратит силы на суточный профиль и на разницу масштабов вестибюлей, а учит только «насколько сегодня не как обычно». Цель «отношение к норме» лучше, чем  $\log(1 + y)$ : 5,49 % против 5,76 %.

**12. Почему LightGBM?** Данные табличные, нужные зависимости — взаимодействия (час × вестибюль × текущее отклонение); LightGBM сам работает с пропусками и категориями и учится

за секунды. Сравнение в тех же условиях: линейная модель 5,70 %, CatBoost 5,56 %, XGBoost 5,61 %, ансамбль 5,50 % против 5,51 % у LightGBM.

**13. Что такое q10, q50, q90 и зачем три модели?** Три квантиля распределения прогноза: q50 — медиана, [q10; q90] — интервал на 80 %. У каждого своя функция потерь pinball: при  $\alpha = 0,9$  недооценка штрафует в 9 раз сильнее переоценки. Распределение несимметрично, поэтому «среднее  $\pm$  разброс» не подходит.

**14. Зачем веса строк?** Метрика WAPE взвешена потоком: ошибка в час пик на большом вестибюле важнее, чем ночью на малом. Без весов малые вестибюли и крайние часы (05, 23, 00) тянули бы модель на себя. Вес — норма  $f_{ref}$ .

**15. Какие признаки главные?** По важности: отклонение всей линии — 17 %, отклонение в тот же час вчера — 13 %, отклонение последнего часа — 12 %, вестибюль — 9 %, норма — 8 %, уровень — 5 %. Без группы «кросс» модель теряет 0,13 п. п., без «вчера» — 0,14.

**16. Почему нет признаков даты и месяца?** В тестовом месяце они принимают значения, которых модель не видела, и дерево ведёт себя непредсказуемо. Отсутствие таких признаков проверяет тест.

**17. Что такое конформная калибровка?** Модель, которая не видела последние 4 недели обучения, прогнозирует их; по её промахам за границы q10 и q90 считаем, насколько раздвинуть интервал (отдельно вниз и вверх). Покрытие стало 80,3 % вместо 73,4 %.

**18. Почему погода почти ничего не добавляет?** Дождь снижает вход всего на 4,5 %, это меньше разброса слота ( $\pm 11,4$  %). В аблиции погода прошла на грани: +0,03 п. п. [+0,01; +0,05]. Оставили как устойчивый, хотя слабый сигнал.

**19. Как получаются «три причины» прогноза?** Предсказание деревьев раскладывается на вклады признаков (значения SHAP для деревьев). Берутся три самых больших по модулю, текст строится по значению признака: «в последний час поток на 75 % ниже нормы». Сумма вкладов равна прогнозу — это проверяет тест.

**20. Почему модель работает на вестибюлях, а не на станциях?** Вестибюли одной станции работают в разном режиме (пл. Ленина-2 закрывается в 22 ч, Ленинский пр.-2 работает 06–21), и при инциденте поток перетекает между ними. Суммирование до станции стёрло бы это. В контракт q50 станции — сумма q50 вестибюлей, интервал станции калибруется отдельно.

**21. Зачем два горизонта и чем они отличаются?** Прогнозируем 1 и 2 часа: WAPE 5,33 % и 5,68 %. Отклонение затухает, поэтому на втором часе выигрыш от динамики примерно в 1,4 раза меньше.

## Проверка

**22. Почему WAPE?** Это суммарная абсолютная ошибка медианного прогноза, делённая на суммарный поток. Ошибка на Девяткино II в час пик весит больше, чем на малом вестибюле ночью, — так и нужно для планирования составов.

**23. Что такое фолд и зачем зазор?** Фолд — одно разбиение «обучение — тест»; у нас 4 (май–август) с расширяющимся окном. Зазор 7 суток нужен потому, что признаки смотрят назад до 168 часов: без зазора последние дни обучения и первые дни теста были бы почти одинаковыми.

**24. Почему не случайное разбиение?** Модель обучалась бы на будущем и проверялась на прошлом, а соседние часы одного дня попадали бы и в обучение, и в тест. Для временных рядов это утечка.



**25. Что такое утечка и как вы её проверяли?** Утечка — когда признак использует то, чего нет в момент прогноза. Проверка: удаляем поток после конца часа  $t$ , пересобираем признаки — они должны совпасть (три точки: 08.07 09:00, 31.08 08:00, 15.06 04:00). Тест падает, если подложить признак из часа  $t + 1$ . Режим повтора проверен подменой будущего шумом.

**26. Зачем заморозка с хэшами?** Чтобы нельзя было подправить модель после финального теста. В `model_final.json` записаны конфигурация (хэш 2152d675...) и хэши пяти файлов кода, поставлен `freeze-before-final`. Команда теста сверяет хэши и повторно не запускается.

**27. Как читать  $\Delta WAP$ , ДИ и  $p$  Диболда–Мариано?**  $\Delta WAP$  — разница ошибок в процентных пунктах, плюс означает, что наша модель лучше. ДИ — интервал блочным бутстрепом по дням: если он весь выше нуля, выигрыш не случаен.  $p$  DM — тест, что модели точны по-разному, с учётом зависимости ошибок.

**28. Что такое абляция?** Проверка пользы частей модели: группы признаков добавляем по одной и смотрим на ошибку. Группа остаётся, если средний выигрыш  $> 0$  и он положителен минимум в 3 фолдах из 4.

**29. Почему в сентябре ошибка 7,72 %, а не 5,51 %? Это провал?** Нет, сентябрь труднее: ступенька уровня +13,5 % и новый учебный год, норма за 4 недели отстаёт. В первую половину сентября ошибка 9,77 %, во вторую, когда норма догнала уровень, — 5,84 %. Выигрыш у лучшего правила при этом вырос: с 1,16 до 1,89 п. п.

**30. Сколько раз вы смотрели на сентябрь?** Финальный тест — один раз (повторный запуск команда не разрешает). Потом сентябрь использовался «для информации»: сравнение моделей (один прогон), ранний сигнал по 15-минутным данным и стекинг — везде с пометкой, что часовые результаты по сентябрю уже известны.

**31. Что значит «вне выборки»?** Прогноз сделан моделью, обученной раньше предсказываемого периода с зазором в 7 суток. Например, для мая — `lgbm_fold_2026-05`, обучена по 23.04. В режиме повтора это видно в `meta.out_of_sample`.

## Продукт

**32. Как команда получает прогноз?** По общему контракту: `records` (`q10`, `q50`, `q90`, `baseline`, `is_anomaly`), `explanations` (три причины) и `meta`. Схема — `pydantic` и `JSON Schema` для любого языка. Вызов `serve.forecast(now)` по умолчанию отвечает стекингом: 18 станций  $\times$  4 получасовых слота, горизонты 30–120 мин, около 3 секунд. Где 15-минутных данных нет, отвечает часовая `LightGBM` — 18 станций  $\times$  2 горизонта (60 и 120 мин) — и пишет причину в `meta["fallback"]`.

**33. Что такое флаг аномалии и почему он слабый?** Флаг —  $|q50 / \text{норма} - 1|$  выше порога `r80` группы и периода суток. На бэкteste `precision` 0,33, `recall` 0,30, `F1` 0,32; в сентябре 0,49 / 0,66 / 0,56. Слабый, потому что предсказывает аномалию за 1–2 часа до неё: провал 31.08 в 08 ч в 07 ч не виден никому.

**34. Что такое режим повтора?** Прогноз на любой исторический момент «как будто сейчас»: данные после этого момента не используются (проверено подменой шумом). Модель выбирается по дате: самая свежая из обученных не позже чем за 7 суток до момента.

**35. Есть ли живой поток?** Нет. Поток в данных заканчивается 29.09; `forecast()` на сегодня отвечает «вне периода данных». Ветка Яндекс Погоды в «боевом» режиме заработает вместе с живым потоком.

**36. Что LLM-слой берёт у вас?** Три причины прогноза словами. Контекст поездов и событий идёт отдельно в `explanations[ ].context`; модель события и поезда не использует, потому что не обучена на них.

**37. Что такое baseline в контракте?** Норма: сумма b4 вестибюлей станции. Флаг аномалии сравнивает с ней q50.

**38. Что передано команде?** Контракт и заглушка, прогнозы на август (22 320 записей), режим повтора, модели (собираются командами примерно за 5 минут), документация, графики, профиль внутри часа `intrahour_profile.csv` для симулятора.

**39. Что дальше для продукта?** Живой поток, 10-минутные данные, скользящая калибровка интервала и решение роли 4: нужен ли ранний детектор при примерно 1,5 ложной тревоге на вестибюль в сутки.

### Каверзные вопросы

**40. Почему не нейросеть?** Данных 9 месяцев; данные табличные; ТЗ сознательно исключало нейросети. Бустинг ловит взаимодействия, обрабатывает пропуски и категории и обучается за секунды. Когда мы всё же проверили GRU, она сама оказалась слабее: 7,96 % против 7,13 % у LightGBM.

**41. Что дала нейросеть?** Сама по себе — ничего: хуже LightGBM. В ансамбле даёт пользу в двух местах: аномальные часы (+0,56 п. п. [+0,37; +0,75]) и интервал (покрытие 78,5 % против 69,3 %). В среднем выигрыш всего +0,05 п. п.

**42. Как нейросеть работает с бустингом?** Модели не сливаются: каждая даёт свой прогноз, а мета-модель-судья берёт их взвешенно по каждому горизонту и квантилю. В медиане LightGBM весит 0,70–0,90, GRU — 0–0,15; для верхней границы q90 GRU весит 0,20–0,35. Если вес одной модели равен 1, ансамбль в точности равен ей.

**43. Нейросеть учили отдельно на 15-минутках?** Нет. Она учится на тех же месяцах (февраль, май, июль), что и вся система, и видит те же данные, но мелким 15-минутным шагом за последние 4 часа. Окно расширяется: для мая — февраль, для июля — февраль + май, для сентября — февраль + май + июль.

**44. Откуда вы знаете, что не подогнали?** Сентябрь закрыт от любого кода до заморозки; модель заморожена с хэшами и протестирована один раз; бэкtest идёт вперёд по времени с зазором; тесты проверяют утечку; гиперпараметры не подбирались; отбор признаков видел только апрель–август. Честная оговорка: разведочный анализ видел и тестовые месяцы, но использовался только для разметки срезов, а не для обучения.

**45. Что если данные врут?** Мы это проверяли: контрольные суммы сходятся (164 876 717 + 418 = 164 877 135), даты проверены правилом «08 ч / 12 ч», сдвиг часов найден и исправлен, 31 час с расхождением источников исключён из оценки. Модель использует медианную норму, устойчивую к необычным дням. Открытый вопрос к организаторам — какой источник пойдёт в живой поток: 15-минутный выше часового на 1,15 %.

**46. Зачем вы включили стекинг, если ваше же правило на мае не выполнено?** Это решение команды, и мы его не прячем. Правило, поставленное заранее (лучше LightGBM и на мае, и на июле), на мае не выполнено: ДИ [–0,00; +0,10]. Но в аномальных часах, где решается вопрос о резерве, стекинг точнее на 0,56 п. п. [+0,37; +0,75], а интервал честнее (78,5 % против 69,3 %). Для продукта это важнее средней цифры. Результаты записаны как есть, риски названы, откат — `model="lgbm"`.

**47. Выигрыш 0,05 п. п. — это вообще что-то?** Статистически значим (+0,05 [+0,02; +0,08] на мае и июле), но на практике почти незаметен. Реальная польза — в аномальных часах (+0,56

п. п.) и в честности интервала: ради них команда и включила стекинг. На сдвиге уровня в сентябре выигрыш втрое больше (+0,18 п. п.).

**48. Что будет, если завтра случится инцидент?** Сам провал мы не предскажем: прогноз сделан до инцидента и даёт норму. Но откат модель ловит: 31.08 на «Девяткино» на 09 ч она дала 7 178 при факте 8 445, а простое правило — 2 849. Флаг аномалии стоял на всех станциях инцидента.

**49. Почему модель хуже простого правила в аномальных часах?** На бэкteste 17,95 % против 16,43 %. Модель выучила, что крайнее отклонение откатывается (как 31.08), и поэтому недооценивает устойчивый всплеск («Алые паруса»). Смесь с правилом улучшала аномальные часы до 16,96 %, но общий WARE терял 0,06 п. п. при допуске 0,02 — не принята. В сентябре на сдвиге модель уже не хуже правила: 13,14 % против 14,16 %.

**50. Что считать успехом, если ошибка 5,5 %?** Шум одного слота вокруг нормы — p50 5,0 % и p80 11,4 %, поэтому ошибка в 5,5 % того же порядка, что случайный разброс. Цель — не ноль, а быть лучше простых правил (+1,16 и +1,89 п. п.,  $p < 0,001$ ) и давать честный интервал. На сентябре, где данные сдвинулись, выигрыш даже вырос.

## Сценарий презентации на 5 минут

**Формат.** 9 слайдов. У каждого слайда: заголовок, крупные пункты (3–5), картинка из reports/figures/ и текст «что говорить вслух». Весь текст вслух — около 650 слов, примерно 5 минут при спокойном темпе. Ключевой слайд — седьмой, демо 31.08: на него уходит минута.

| № | Слайд                                      | Время        |
|---|--------------------------------------------|--------------|
| 1 | Прогноз входов на станции метро            | 20 с         |
| 2 | Проблема: резерв выходит за 15–20 минут    | 30 с         |
| 3 | Данные и ловушки                           | 35 с         |
| 4 | Главная идея: отклонение держится 2–3 часа | 35 с         |
| 5 | Как работает модель                        | 40 с         |
| 6 | Честная проверка                           | 35 с         |
| 7 | <b>Результат и демо 31.08</b>              | 60 с         |
| 8 | Слабые места и что дальше                  | 30 с         |
| 9 | Итог                                       | 15 с         |
|   | <b>Всего</b>                               | <b>5 мин</b> |

**Если времени мало:** слайды 2 и 6 можно сократить до одной фразы, слайд 7 не сокращать.

### Слайд 1. Прогноз входов на станции метро на 1–2 часа вперёд

На слайде:

- 1 линия метро СПб, 18 станций;
- прогноз каждый час: медиана и интервал  $q_{10}$ – $q_{90}$ , норма, флаг аномалии, три причины;
- ML стоит в начале цепочки: симулятор → рекомендации → дашборд.

**Картинка:** docs/report/figures/fig\_system.png — схема системы.




**Говорить вслух (20 с).** Мы прогнозируем, сколько людей войдёт на каждую станцию первой линии в ближайшие один и два часа. Прогноз получает симулятор загрузки, потом рекомендации по составам и дашборд, так что от его точности зависит вся цепочка.

## Слайд 2. Проблема: резерв выходит за 15–20 минут

На слайде:

- резервный состав выходит на линию за 15–20 минут;
- полный оборот — 99 минут, в резерве 4 состава, парность до 32 пар в час;
- нужно знать поток заранее: на 1–2 часа вперёд;
- дальше смотреть не имеет смысла: отклонение от нормы живёт 2–3 часа.

**Картинка:** reports/figures/spb\_01\_profiles.png — суточные профили: у спальных станций утренний пик, у центра вечерний.




**Говорить вслух (30 с).** Резервный состав выходит на линию за 15–20 минут, полный оборот занимает 99 минут, в резерве четыре состава. Чтобы вовремя добавить поезда, нужно знать поток заранее. Поэтому горизонт — один и два часа: короче поздно, а длиннее прогноз теряет ценность, потому что отклонение от нормы живёт два–три часа.

### Слайд 3. Данные и ловушки

На слайде:

- 23 вестибюля × 6 528 ч = 150 144 строки, 164 876 717 входов;
- ловушка 1: даты — текст, строки в перепутанном порядке;
- ловушка 2: часы 00–02 подписаны датой прошедших суток (доказали тремя признаками);
- ловушка 3: режимы закрытия вестибюлей, инцидент 31.08, закрытия входа в пик.

**Картинка:** reports/figures/spb\_07\_incident.png — инцидент 31.08 по вестибюлям.




**Говорить вслух (35 с).** Организаторы дали почасовые входы по 23 вестибюлям за девять месяцев; пока их не было, мы отладили конвейер на открытых данных метро другого города. В реальных данных были ловушки: даты шли текстом в перепутанном порядке; часы с полуночи до двух подписаны датой прошедших суток, и мы доказали это тремя независимыми признаками; вестибюли закрываются по режиму; плюс инцидент 31 августа. Каждую ловушку учли флагом и всё пересчитали.

### Слайд 4. Главная идея: отклонение от нормы держится 2–3 часа

На слайде:

- норма — «сколько обычно в этот час»; отклонение  $r = \text{факт} / \text{норма}$ ;
- корреляция отклонения с лагом 1 / 2 / 3 часа: 0,72 / 0,59 / 0,44;
- после часа с  $r > 1,15$  такое же отклонение остаётся в 50 % следующих часов (в среднем — 11 %);
- «норма × текущее отклонение»: ошибка 8,53 → 6,74 %.

**Картинка:** reports/figures/spb\_08\_persistence.png — три панели: лаги, распределение после  $r > 1,15$ , связь утра с вечером.




**Говорить вслух (35 с).** Главная идея простая: если в этот час людей больше обычного, то и в ближайшие два-три часа их будет больше. Корреляция с лагом в час — 0,72, в три часа — 0,44. После часа с отклонением больше 15 % такое же отклонение остаётся в половине следующих часов, а в среднем — только в 11 %. Даже простое правило «норма на текущее отклонение» снижает ошибку с 8,5 до 6,7 %.

## Слайд 5. Как работает модель

На слайде:

- норма = медиана того же часа за 4 последних таких же дня × поправка на уровень недели;
- модель учит отклонение от нормы, а не сам поток;
- три LightGBM: q10, q50, q90; 26 признаков: последний час, вся линия, соседи, вчера, дождь;
- интервал калибруем: покрытие 73,4 % → 80,3 %.

**Картинка:** docs/report/figures/fig\_calibration.png — покрытие интервала до и после поправки.




**Говорить вслух (40 с).** Норма — медиана того же часа за четыре последних таких же дня с поправкой на уровень недели. Модель учит не сам поток, а отклонение от нормы. Три модели LightGBM дают нижнюю границу, медиану и верхнюю границу; на входе 26 признаков: последний час, вся линия, соседи, вчера и дождь. Сырой интервал был узким — покрывал 73 % вместо 80. Конформная калибровка подняла покрытие до 80,3 %.

## Слайд 6. Честная проверка

На слайде:

- бэктест на 4 месяцах: расширяющееся окно, зазор 7 суток;
- сентябрь закрыт от любого кода, открыт один раз;
- заморозка: хэши конфигурации и кода, тег `freeze-before-final`;
- тесты на утечку: поток после момента прогноза не меняет признаки.

**Картинка:** `docs/report/figures/fig_folds.png` — фолды, зазор и закрытый сентябрь.



**Говорить вслух (35 с).** Проверка идёт вперёд по времени: четыре месяца с расширяющимся окном и неделей зазора. Сентябрь был закрыт от любого кода. Модель заморозили с хэшами конфигурации и кода, поставили тег — и только потом запустили тест, ровно один раз. Утечку проверяют тесты: если обрезать поток после момента прогноза, признаки не меняются.




## Слайд 7. Результат и демо 31.08 (ключевой)

На слайде:

- **31.08:** на Девяткино в 08 ч вошло 3 969 при норме 13 942 (инцидент на «Чернышевской»);
- прогноз на 09 ч в 08:59: простое правило — 2 849, **модель — 7 545**, факт — 8 445, норма — 8 295;
- модель поняла, что такой провал не держится; сам провал не предсказывает никто;
- итог: 5,51 против 6,66 % (бэкtest) и 7,72 против 9,61 % (закрытый сентябрь).

**Картинка:** reports/figures/spb\_15\_demo\_0831.png — станция Девяткино, прогнозы на 1 и 2 часа; оранжевая линия — простое правило, синяя — модель. Вторая картинка — лестница WAPE spb\_14\_wape\_ladder.png.

**Демо-кейс 31.08: провал из-за инцидента и откат спроса, Девяткино**  
прогнозы model\_aug.json и baseline\_aug.json: обучение до 24.07, вне выборки



**Говорить вслух (60 с).** Ключевой пример — 31 августа. На «Девяткино» в восемь утра из-за остановки на «Чернышевской» вошло 3 969 человек при норме почти 14 тысяч. В 08:59 мы прогнозируем девять часов. Простое правило переносит провал вперёд: 2 849. Наша модель, обученная до 24 июля, то есть не видевшая этот день, даёт 7 545 при факте 8 445. Она выучила, что такой провал вместе с провалом всей линии не держится. Сам провал в восемь часов не предсказывает никто, и откат вышел выше нашего интервала — это мы честно показываем. Итог по метрикам: 5,51 процента против 6,66 на бэкtestе и 7,72 против 9,61 в закрытом сентябре.

*Примечание для себя.* График построен моделью фолда «август» (обучена до 24.07): 7 545. В режиме повтора (python -m src.serve --now "2026-08-31 08:59") отвечает lgbm\_holdout (обучена по 24.08): 7 178 [6 910; 7 552]. Если жюри спросит про расхождение

— это одна конфигурация на разной длине истории; правило и факт те же. Стекинг для 31.08 не отвечает: за август нет 15-минутных данных, и `serve` сам отдаёт часовую LightGBM.


## Слайд 8. Слабые места и что дальше

На слайде:

- аномальные часы: 17,95 % у модели против 16,43 % у простого правила;
- интервал в сентябре покрыл 71,7 % вместо 80 %; флаг тревог шумный (F1 0,32 на бэк-тесте);
- стекинг с нейросетью GRU включили в продукт: в среднем +0,05 п. п. (на мае незначимо), но в аномальных часах +0,56 п. п. и интервал честнее (78,5 % против 69 %) — осознанный компромисс;
- дальше: 10-минутные данные, скользящая калибровка, стекинг на большем объёме данных.

**Картинка:** `reports/figures/spb_17_wape_horizon.png` — WAPE получасовых прогнозов: стекинг против частей.

Прогноз каждые 30 минут: точность по горизонтам



**Говорить вслух (30 с).** Слабые места мы измерили. В аномальных часах модель хуже простого правила: 17,95 процента против 16,43. Интервал на сдвиге уровня в сентябре покрыл 72 процента вместо 80. Флаг тревог шумный. Ещё мы проверили ансамбль с нейросетью: в среднем он лучше всего на 0,05 пункта, но в аномальных часах — на 0,56, и интервал честнее. Поэтому команда включила его в продукт, хотя наше же правило на мае не выполнено, — это осознанный компромисс. Дальше — десятиминутные данные и скользящая калибровка.

## Слайд 9. Итог

На слайде:

- модель точнее лучшего простого правила на 1,16 п. п. (бэк-тест) и 1,89 п. п. (сентябрь),  $p < 0,001$ ;
- проверка честная: сентябрь закрыт, модель заморожена, тест один раз;
- слабые места известны и измерены;
- результат передан команде по общему контракту.

**Картинка:** не нужна — оставить на экране таблицу с главными цифрами.

**Говорить вслух (15 с).** Итог: модель точнее лучшего простого правила на 1,16 и на 1,89 процентного пункта, проверена честно и заморожена, а слабые места известны и измерены. Готовы к вопросам.