

Подготовка к защите

Шпаргалка к защите и сценарий презентации на 5 минут. ML-часть проекта:
прогноз входов на станции 1 линии метро СПб

Команда проекта, ML-часть

Октябрь 2026

Содержание

Шпаргалка к защите	3
Часть 1. Как устроен проект	4
1. Задача за 30 секунд	4
2. Данные	4
3. Норма	6
4. Главная идея: отклонение от нормы держится 2–3 часа	7
5. Признаки	7
6. Отбор признаков	9
7. Модель под капотом	10
8. Интервал и калибровка	12
9. Честная проверка	13
Часть 2. После финального теста: стекинг (в продукте) и 15-минутные данные	15
10. Стекинг (ансамбль): LightGBM + персистентность + GRU	15
11. 15-минутные данные и ранний сигнал	18
12. Результаты одной таблицей	19
13. Слабые места честно и что дальше	20
14. Демо 31.08 по шагам	21
Часть 3. 50 вопросов жюри и короткие ответы	23
15. Вопросы и ответы	23
Сценарий презентации на 5 минут	28
Слайд 1. Прогноз входов на станции метро на 1–2 часа вперёд	28
Слайд 2. Проблема: резерв выходит за 15–20 минут	29
Слайд 3. Данные и ловушки	30
Слайд 4. Главная идея: отклонение от нормы держится 2–3 часа	30
Слайд 5. Как работает модель	31
Слайд 6. Честная проверка	32
Слайд 7. Результат и демо 31.08 (ключевой)	33
Слайд 8. Слабые места и что дальше	34
Слайд 9. Итог	34

Шпаргалка к защите

Для кого. Для автора ML-части. Цель — понять проект насквозь и ответить на любой вопрос жюри.

Как читать. Каждый раздел построен одинаково:

- **Простыми словами** — смысл без терминов и зачем это нужно;
- **Подробнее** — то же точно, с формулами и числами;
- **Наш пример** — реальные цифры проекта;
- **Что ответить, если спросят** — короткая формулировка для жюри.

Все цифры взяты из docs/* .md, docs/report/report .md и reports/. Если цифра приведена без источника, её можно найти в отчёте по названию раздела. В конце — 50 вопросов жюри с короткими ответами.

Три цифры, которые стоит помнить:

- **5,51 % против 6,66 %** — ошибка модели против лучшего простого правила на бэкteste (май–август);
- **7,72 % против 9,61 %** — то же на закрытом сентябре, один запуск;
- **+0,05 п. п. в среднем, но +0,56 п. п. в аномальных часах** — выигрыш стекинга у обычной LightGBM; команда включила его в продукт ради аномальных часов и честного интервала, хотя заранее поставленное правило на мае не выполнено.

Часть 1. Как устроен проект

1. Задача за 30 секунд

Простыми словами. Метро решает, сколько поездов пустить и когда вывести резервный состав. Для этого нужно знать, сколько людей придёт на станции в ближайшие часы. Мы предсказываем, сколько человек пройдёт через турникеты на вход в каждой станции 1 линии на следующий час и на час после него.

Подробнее.

- **Что на выходе** (часовая модель — раз в час, в конце часа): медианный прогноз q_{50} и интервал q_{10} – q_{90} («факт попадёт сюда в 80 % случаев»); норма для этого часа; флаг аномалии; три причины прогноза словами для LLM-слоя.
- **Что в продукте по умолчанию.** `serve.forecast(now)` отдаёт **стекинг**: прогноз каждые 30 минут на 4 получасовых слота вперёд (горизонты 30 / 60 / 90 / 120 мин), состав выхода тот же. Где 15-минутных данных нет — часовая модель, как выше (раздел 10).
- **По каким объектам:** 18 станций 1 линии (у «Технологического института» нет часовых данных). Внутри модель считает 23 вестибюля, а в контракт прогноз уходит по станциям.
- **Место в системе.** Наша часть — ML. Прогноз идёт симулятору загрузки перегонов, потом рекомендациям по парности и резерву, потом дашборду. Если прогноз ошибается, ошибаются все следующие части.

Почему горизонт 1–2 часа.

- По данным организаторов, резервный состав выходит на линию за 15–20 минут, полный оборот «туда–обратно» занимает 99 минут, в резерве 4 состава. Прогноз на 1–2 часа покрывает это время с запасом.
- Дальше ценность прогноза падает: главный сигнал — отклонение от нормы — держится 2–3 часа.
- На втором часе выигрыш от динамики примерно в 1,4 раза меньше, чем на первом.

Наш пример. Максимальная парность на 1 линии — 32 пары поездов в час. В сентябре в 08 ч в линию входит 74,7 тыс. человек, а провозная способность $32 \text{ пар} \times 1458 = 46,7 \text{ тыс.}$ на направление (грубая оценка: в данных только входы).

Что ответить, если спросят. «Мы прогнозируем входы на станции на 1 и 2 часа вперёд, потому что резерв выходит за 15–20 минут, а отклонение от нормы живёт 2–3 часа. Дальше прогноз уже мало что добавляет. В продукте по умолчанию прогноз обновляется каждые 30 минут — это стекинг поверх часовой модели».

2. Данные

Простыми словами. Организаторы дали выгрузку турникетов: сколько человек вошло через каждый вестибюль в каждый час с января по сентябрь 2026. Пока этих данных не было, мы отлаживали весь конвейер на открытых данных метро другого города — загрузку, очистку, контракт, разведочный анализ. Потом всё переехало на данные СПб.

Подробнее — что дали организаторы.

Файл	Что внутри	Кто использует
Пассажиропоток 2026 Линия 1	почасовые входы по 23 вестибюлям, 01.01–30.09.2026	ML, основной источник
Входные потоки по 15 минут	февраль, май, июль, сентябрь, 24 вестибюля	ML, этап 6 и стекинг

Файл	Что внутри	Кто использует
График движения, парность, вместимость	интервалы, пары по часам, 1 458 человек на состав	рекомендации, симулятор
Пример остановки обслуживания	инцидент 31.08, 07:50–10:31, «Чернышевская»	разметка и демо
Форма МО-I	выполнение графика, 3 периода	экономика

Наш пример (цифры).

- После очистки: 23 вестибюля × 6 528 ч = **150 144 строки**, 164 876 717 входов, без дубликатов и пропусков.
- В рабочий день на линию в среднем входит 695 тыс. человек. Самый загруженный вестибюль — Девяткино II: 63,0 тыс.
- Контрольная сумма: сумма входов плюс 418 входов отброшенной метки совпадает со строкой итога файла (164 877 135).

Какие ловушки нашли в данных СПб. Каждая искажила бы признаки или метрики, если бы её не заметили.

Ловушка	Как нашли	Что сделали
Служебные строки: «Сводка» сверху и итог снизу	при первом чтении	обрезали; итог и «Сводку» используем как контрольные суммы
Дата — текст «ДД.ММ.ГГГГ ЧЧ», строки отсортированы как строки: сначала первое число каждого месяца	порядок строк не совпадал со временем	строгий разбор формата, сортировка по времени; проверка: «08 ч / 12 ч» > 1,2 ровно в рабочие дни, при перепутанных день/месяц не сходятся 42 из 108 дней
Часы 00–02 подписаны датой прошедших суток: «27.06 01» — это 28.06 01:00	три признака (ниже)	перевели метки в реальное время; особых ночей стало 4 вместо 7
Режимы вестибюлей: Ленинский пр.-2 работает 06–21, пл. Ленина-2 — 05–22	доля дней с входом по часам	флаг «вестибюль закрыт»
Инцидент 31.08	материалы организаторов и данные	флаг на всей линии, 07–11 ч
Особые ночи: метро работало, когда обычно закрыто (Новый год, Рождество, 29→30.05, «Алые паруса»)	ненулевые входы в 01–04 ч	внесены в справочник событий
Частичные закрытия входа в пик: Балтийская 08:15–09:15 (до ~19.03), Нарвская 08:15–09:00 (18.06–28.08)	15-минутные данные; часовые флаги их не видят	флаг is_slot_closed; «×2,69 на Нарвской» 31.08 — в основном конец этого режима
Два источника: 15-минутный выше часового на 1,15 %	сверка «сумма 4 четвертей = час»	истина — часовой файл, 15-минутный сигнал делим на поправку s_v

Как нашли сдвиг часов 00–02 (самая коварная ловушка — данные выглядели правильными):

- вход в 00 ч по меткам пятницы и субботы выше остальных дней: 1 736 и 1 887 против 976–1 180;
- аномалия часа «D 00» связана с аномалией «D 23» на 0,76 и с «D-1 23» только на 0,35;
- ночь «Алых парусов» непрерывна только при сдвиге: 8,6, 13,0, 5,6, 4,9 и 3,8 тыс. входов в 00–04 ч.

После исправления очистку перезапустили, и все выводы посчитаны уже на исправленных данных.

Что это говорит о нашей работе. Мы не верим выгрузке на слово: сверяем контрольные суммы, проверяем гипотезы на данных, находим и исправляем собственные ошибки и пересчитываем всё заново.

Какие ещё сервисы использовали (модули `external_data`, их делал Денис; в ML-часть подключены через `src/external_adapter.py`):

- **Погода.** Open-Meteo — исторический прогноз осадков для обучения. Яндекс Погода — источник того же признака в «боевом» режиме: часы сдвигаются на +1 ч, потому что Open-Meteo метит час концом, а Яндекс — началом. Нет ключа или ошибка API — откат на Open-Meteo с предупреждением.
- **Календарь.** `isdayoff.ru` — тип дня с переносами; названия праздников — из `holidays.RU`.
- **События и новости.** Модуль принимает тексты (в том числе из Telegram) и извлекает события через YandexGPT или OpenRouter; геокодер Яндекса привязывает событие к ближайшей станции.
- **Поезда.** Яндекс Расписания — прибытия на 4 вокзала.

Честно: события и поезда идут только в `explanations[ ].context` для LLM-слоя. В модель они не подаются, потому что она на них не обучена. Живого потока данных пока нет: «сейчас» работает только в тестах.

Что ответить, если спросят.

- «Откуда данные?» — «Выгрузка турникетов 1 линии за 9 месяцев от организаторов, плюс календарь, погода и справочник событий. До их получения отлаживали конвейер на открытых данных метро другого города».
- «Какие проблемы были в данных?» — «Сдвиг подписи часов 00–02, перепутанный порядок дат, режимы закрытия вестибюлей, инцидент и частичные закрытия входа в пик. Каждую нашли проверкой и учли флагами».

3. Норма

Простыми словами. Норма — это «сколько обычно входит в этот вестибюль в этот час в этот день недели». Если во вторник в 08:00 обычно заходит 3 000 человек, то 3 000 — это норма. Всё интересное — в отклонении от неё.

Подробнее.

- **b4 (основная норма)** — медиана того же вестибюля, часа и дня недели по 4 последним обычным таким же суткам (поиск до 8 недель назад). В историю не идут праздники, события, 1–11 января и часы с флагами. Только прошлое.
- **Праздник или нерабочий будний день** — норма по 4 последним обычным воскресеньям: форма потока будних праздников совпадает с воскресной (корреляция 0,994), а уровень на 36–47 % ниже будней.
- **Поправка на уровень** — медиана суточного отношения «факт / норма» по 7 последним обычным суткам. Итоговая опорная норма модели: $f_ref = b4 \times \text{уровень}$.

Почему медиана, а не среднее. Один необычный день — с закрытием или дождём — не сдвигает медиану, а среднее сдвигает.

Почему 4 недели, а не 8. Длинная норма сильнее отстаёт от тренда: WAPE 8,97 % против 7,59 %.

Почему по дню недели, а не по типу дня. Понедельник на 3,1 % ниже вторника–четверга, пятница на 1,4 % выше. Разброс ($p95 |r - 1|$) при норме по дню недели 22,5 %, при норме по типу дня 25,7 %.

Почему нужна поправка на уровень. Норма смотрит на прошлые недели, а поток меняется: летом падает, в сентябре скачет вверх. Около 40 % связи нашего главного признака с целью — просто общий уровень месяца. Уровень закрывает это отставание. В июле он около 0,94, 10 сентября — 1,13. Сама по себе поправка снижает WAPE нормы с 7,59 до 6,83 %.

Наш пример. 23.02 (праздник) в 08 ч у Девяткино II норма по воскресеньям — 2 674 при факте 2 740. Понедельничная норма была бы 10 084 — ошибка почти в четыре раза.

Что ответить, если спросят. «Норма — медиана того же часа в 4 последних таких же днях. Медиана устойчива к необычным дням. Поправка на уровень закрывает отставание нормы от тренда: без неё в сентябре, когда поток вырос на 13,5 %, норма сильно занижала бы».

4. Главная идея: отклонение от нормы держится 2–3 часа

Простыми словами. Если сегодня в 08:00 людей вошло на 30 % больше обычного, то вероятнее всего и в 09:00, и в 10:00 их тоже будет больше обычного. «Сегодня не как всегда» — это не случайный шум, а состояние дня: ливень, мероприятие, каникулы, сбой на соседней линии. Поэтому по последним часам можно судить о ближайших.

Подробнее — откуда это узнали на разведочном анализе.

- Отклонение r = факт / норма. Корреляция логарифма r с лагом 1 / 2 / 3 часа — медиана 0,72 / 0,59 / 0,44.
- После часа, в котором $r > 1,15$, выше 1,15 остаётся 50 % следующих часов (в среднем без условия — 11 %). Через два часа — 44 %.
- Утро подсказывает вечер: накопленное с открытия отклонение до 09 ч связано с r в 17–18 ч того же дня (корреляция Спирмена 0,48).
- Линия задаёт фон дня: корреляция r вестибюля с r всей линии 0,62, с соседними станциями 0,45.

Наш пример (простые прогнозы, WAPE). Одна лишь норма b ошибается на 8,53 %. «Норма $\times r(t)$ » — норма, умноженная на отклонение последнего часа, — ошибается на 6,74 %, на 1,79 п. меньше (ДИ 1,13...2,54). На втором часе выигрыш в 1,4 раза меньше — отклонение затухает.

Что ответить, если спросят. «Главный сигнал — отклонение от нормы, оно держится 2–3 часа. На разведочном анализе: корреляция с лагом 1 час — 0,72, 2 часа — 0,59, 3 часа — 0,44; после часа с отклонением больше 15 % такое же отклонение остаётся в половине следующих часов против 11 % в среднем. Простое правило „норма $\times$ текущее отклонение“ уже снижает ошибку с 8,5 до 6,7 %».

5. Признаки

Простыми словами. В данных всего три колонки: вестибюль, час, входы. Всё остальное мы придумываем: что было в последний час, что было вчера, что творится у соседей и на всей линии, какой сегодня день, что с погодой. Признак — это число, которое модель получает на вход, чтобы угадать будущее.

Подробнее — как придумывали. Список из 56 кандидатов сложился из пяти идей:

- **динамика** — как поток отличается от нормы прямо сейчас и как менялся;
- **кросс** — что происходит у соседей и на всей линии;
- **«вчера»** — отклонение в тот же час вчера и каким был вчерашний день;
- **календарь** — день недели, праздник;
- **погода** — дождь по прогнозу.

Все признаки считаются только по данным до конца часа t , когда прогноз делается. Признаков месяца и даты нет: в тестовом месяце они принимают значения, которых модель не видела.

Все 26 признаков финальной модели одной фразой (r = факт / норма; f_{ref} — норма с поправкой на уровень):

Имя в коде	Что это простыми словами
vestibule	какой именно вход — у каждого свой характер
station_group	тип станции: спальная конечная, центр и вокзалы, прочая
hour_tau	на какой час прогноз (сутки метро идут от 05 до 00)
dow_tau	какой день недели
day_type_tau	рабочий, суббота, воскресенье или праздник
h	на сколько часов вперёд прогноз — 1 или 2
b4_tau	норма на этот час
level	на сколько последняя неделя выше или ниже нормы
y_t	сколько вошло в последний закрытый час
y_t1	сколько вошло за час до него
y_tau24	сколько входило вчера в тот же час
y_tau168	сколько входило неделю назад в тот же час
r_t	насколько последний час отличается от нормы
ewm_r_2h	устойчивое отклонение за последние ~2 часа (сглаженное)
ewm_r_6h	то же за ~6 часов
cum_ratio	на сколько процентов с открытия вошло больше обычного
ratio_168	последний час против того же часа неделю назад
r_line	отклонение от нормы всей линии — фон дня
ewm_r_line_2h	сглаженное отклонение линии за ~2 часа
r_neighbors	отклонение соседних станций (± 2 по линии) — местная часть
r_twin	отклонение второго вестибюля той же станции
share_dev	доля вестибюля в линии против обычной: «перетекает ли поток»
r_yday	отклонение в тот же час вчера
cum_ratio_yday	каким был вчерашний день целиком
fc_precip_tau	идёт ли дождь ($\geq 0,5$ мм/ч) по прогнозу на этот час
fc_precip_3h_tau	сколько осадков по прогнозу за три часа до этого часа

Группы: база — 12, ядро динамики — 5, кросс — 5, «вчера» — 2, погода — 2.

Что значат слова:

- **Сглаженное (экспоненциальное) среднее** — среднее, в котором недавние часы весят больше; вес старых падает вдвое за «полупериод» (2 или 6 часов). Даёт устойчивое «сегодня выше нормы» без часового шума.
- **Кросс-признаки** — отклонения не своего вестибюля, а соседей и всей линии. Линия задаёт общий фон дня, соседи добавляют местную часть.
- **Динамика** — всё, что описывает недавнее поведение потока.

Какие признаки модель использует сильнее всего (по важности gain): r линии — 17 %, r того же часа вчера — 13 %, $r(t)$ — 12 %, вестибюль — 9 %, норма $b4$ — 8 %, уровень — 5 %.

Что ответить, если спросят. «У нас три колонки, значит, всё держится на признаках. Мы собрали 56 кандидатов по пяти идеям, проверили их статистикой и абляцией и оставили 26. Главные — отклонение линии, отклонение вчера и отклонение последнего часа. Все признаки считаются только по данным до момента прогноза».

6. Отбор признаков

Простыми словами. Из 56 кандидатов не все полезны: часть просто дублирует друг друга, часть — шум. Мы проверяли каждого честным статистическим способом, а потом группами добавляли в модель и смотрели, падает ли ошибка.

Подробнее — как проверяли каждого кандидата (на двух горизонтах, итого 112 проверок):

1. **Сравнение внутри слота «вестибюль × час».** Так суточный профиль и размер вестибюля не создают ложной связи: в 08 ч и поток, и почти любой признак большие. Это стратифицированный Спирмен.
2. **Доверительный интервал блочным бутстрепом по дням.** Перевыбираем целые дни, а не часы: часы одного дня зависимы, и обычный бутстреп занижил бы интервал.
3. **p-value перестановками.** Переставляем целые дни внутри «месяц × рабочий / нерабочий»: зависимость внутри дня и сезонность остаются, рвётся только связь признака с целью.
4. **Поправка Бенджамини–Хохберга** на все 112 тестов: при стольких проверках часть «значимых» была бы случайной.
5. **Стабильность** — знак эффекта совпадает минимум в 75 % месяцев.
6. **Дубли** — если два признака связаны сильнее 0,95, оставляем более сильный.
7. **Польза для прогноза ($\Delta WAPE$).** Апрель–август, сентябрь не видим.

Контрольный шум. В список положили случайный признак. Он не прошёл отбор: p после поправки 0,99. Это проверка самой процедуры: на чистом шуме она не находит «значимого».

Почему поменяли правило.

- **Первое правило** сравнивало эффект признака с шумом слота ($p80 |r - 1| = 11,4 \%$): эффект меньше шума — отбросить. Под него попали почти все признаки динамики.
- **В чём была ошибка.** Шум слота — это разброс одного наблюдения вокруг нормы. Эффект признака — это систематический сдвиг. Признак, который сдвигает прогноз всего на 3 %, всё равно уменьшает ошибку, если сдвигает в нужную сторону в большинстве случаев. Сравнивать эти величины нельзя.
- **Новое правило.** Значимый признак с $\Delta WAPE > 0$ и интервалом выше нуля получает вердикт «проверить в абляции». Сменились 32 вердикта. Итог: на $t+1$ — 9 «брать», 19 «в абляцию», 28 «отбросить»; на $t+2$ — 8 / 19 / 29.

Что такое абляция. «Абляция» — по-русски «отрезание»: проверяем пользу части модели, добавляя группы признаков по одной (или убирая по одной) и измеряя, как меняется ошибка. Группа остаётся, если средний выигрыш > 0 и он положителен минимум в 3 фолдах из 4: так группа, которая случайно помогла в одном месяце, не пройдёт.

Наш пример — таблица абляции ($WAPE$, 4 фолда; выигрыш — $\Delta WAPE$ к предыдущему шагу, п. п.):

Шаг	WAPE	Выигрыш [95 % ДИ]	Фолдов с	
			пользой	Решение
база (без динамики)	6,64 %	—	—	—
+ ядро динамики	5,85 %	+0,80 [+0,63; +0,98]	4 из 4	оставлена
+ кросс	5,66 %	+0,18 [+0,13; +0,24]	4 из 4	оставлена
+ скорость и ускорение	5,67 %	-0,00 [-0,02; +0,01]	2 из 4	отброшена
+ вчера	5,54 %	+0,13 [+0,09; +0,17]	4 из 4	оставлена
+ погода	5,51 %	+0,03 [+0,01; +0,05]	4 из 4	оставлена
+ особые дни	5,49 %	+0,02 [-0,01; +0,05]	1 из 4	отброшена

Почему скорость и ускорение отбросили. Это приросты потока за 1–3 часа и изменение отклонения. По отдельности они выглядели полезными (+0,06...+0,18 п. п.), но всё, что в них есть, уже несёт ядро динамики: поверх него они дают –0,00 п. п., интервал вокруг нуля.

Что показали другие проверки:

- **База без динамики** на уровне простого правила (6,64 % против 6,66 %). Динамика — главный выигрыш.
- **Особые дни** отброшены: в мае в обучении до 23.04 не было ни одного сокращённого дня, и признак не мог ничему научить. Вернуть группу можно, когда в обучении будет 4 таких дня.
- **«Минус одна группа»** от финального набора: без «кросс» модель теряет 0,13 п. п., без «вчера» — 0,14, без ядра — 0,03 (оно дублируется г линией и г вчера), без погоды — 0,03. Все группы нужны.
- **Погода** прошла на грани: дождь снижает вход на 4,5 %, но в июле её выигрыш всего +0,0004 п. п.

Что ответить, если спросят. «Мы проверили 56 кандидатов строгой процедурой: перестановки целых дней, поправка на множественные проверки, контрольный шум. Один раз пересмотрели правило, когда поняли, что сравнивали несопоставимые величины. Окончательное решение принимала абляция на модели: группы добавляли по одной, оставляли тех, кто помогает минимум в 3 фолдах из 4. Скорость и ускорение отбросили: ничего не добавляют поверх динамики».

7. Модель под капотом

Простыми словами. Модель — это набор простых «если... то...» правил, собранных в сотни маленьких деревьев. Каждое следующее дерево исправляет ошибки предыдущих. На входе — 26 признаков, на выходе — «насколько этот час будет отличаться от нормы». Это и называется градиентным бустингом. Мы обучаем три такие модели: одна выдаёт медиану («скорее всего будет столько»), две другие — нижнюю и верхнюю границу («с вероятностью 10 % будет меньше / больше»).

Подробнее.

- **Дерево** — цепочка вопросов: «час = 8? отклонение линии < 0,8? вестибюль = Девяткино II?» — в конце листа число. Одно дерево слабое. **Бустинг** строит их по очереди: каждое учится на остатках предыдущих.
- **LightGBM** — быстрая реализация бустинга. Нам подходит тем, что умеет работать с пропусками (отклонение не определено ночью), с категориями (вестибюль, группа станций, тип дня) и учится за секунды — а мы запускали абляцию много раз.
- **Квантильная регрессия.** Обычная регрессия минимизирует квадрат ошибки и даёт среднее. Мы минимизируем «pinball»: ошибку, у которой недооценка и переоценка штрафуются по-разному:

$$L = \max(\alpha \cdot (y - q), (\alpha - 1) \cdot (y - q)).$$

При $\alpha = 0,5$ это половина абсолютной ошибки — то есть медиана. При $\alpha = 0,9$ недооценка штрафуются в 9 раз сильнее переоценки — модель учит верхнюю границу. Поэтому три модели: $\alpha = 0,1 / 0,5 / 0,9$. После предсказания квантили сортируются, чтобы $q_{10} \leq q_{50} \leq q_{90}$.

- **Зачем квантили, а не «среднее $\pm$ разброс».** Отклонения несимметричны: провалы бывают глубже всплесков, и наоборот — в зависимости от часа и станции. Квантили не требуют предположения о форме распределения.

Почему цель — отклонение от нормы, а не сам поток.

- Модель предсказывает $z = \log((y + 1) / (f_{\text{ref}} + 1))$: логарифм отношения факта к норме. Единицы защищают от нуля в часы с малым потоком. Обратно: $\hat{y} = (f_{\text{ref}} + 1) \cdot e^z - 1$.
- **Зачем.** Отношение снимает с модели две трудные и уже известные вещи: суточный профиль (утром и вечером потока в разы больше) и разницу масштабов вестибюлей (у Десяткино II до 11 тыс. входов в час, у малых — сотни). Остаётся то, что действительно надо угадать: «насколько сегодня не как обычно».
- **Проверили альтернативу $\log(1 + y)$:** отношение лучше — 5,49 % против 5,76 % (+0,27 п. п. [+0,20; +0,32]).
- Если норма меньше одного входа, все квантили равны норме: почти пустой час мы прогнозировать не берёмся.

Веса строк. Каждая строка учится с весом f_{ref} . Метрика WAPE взвешена потоком: ошибка в час пик на большом вестибюле важнее, чем ночью на малом. Без весов цель-отношение учила бы относительную ошибку, и малые вестибюли и крайние часы (05, 23, 00) тянули бы модель на себя.

Параметры — умеренные значения по умолчанию, без подбора: шаг 0,05, 31 лист, лист не меньше 200 строк, до 3 000 деревьев с ранней остановкой (100 итераций без улучшения). Число деревьев на практике от 94 (май, q50) до 1 400 (июль).

Почему LightGBM, а не нейросеть и не линейная модель.

- **Нейросеть.** Данных 9 месяцев; нейросети и графовые модели требуют больше. Исходное ТЗ сознательно их исключало. Позже мы всё же проверили GRU внутри стекинга (раздел 10): сама по себе она слабее — 7,96 % против 7,13 %.
- **Линейная квантильная регрессия** проигрывает всего на 0,19 п. п.: главный сигнал почти линейен. Но бустинг выигрывает на взаимодействиях «час $\times$ вестибюль $\times$ текущее отклонение», а в сентябре интервал линейной модели заметно уже: покрытие 64,4 % против 71,7 %.
- **CatBoost и XGBoost** в тех же условиях чуть хуже; ансамбль LightGBM + CatBoost не отличим от LightGBM.

Наш пример — сравнение моделей (4 фолда, май–август, те же признаки, цель, веса и калибровка):

Модель	WAPE	Разница с LightGBM, п. п. [ДИ]	Вывод
LightGBM (заморожена)	5,51 %	—	официальная
Линейная квантильная регрессия	5,70 %	−0,19 [−0,28; −0,10]	хуже
CatBoost	5,56 %	−0,05 [−0,09; −0,02]	хуже
XGBoost	5,61 %	−0,10 [−0,14; −0,06]	хуже
LightGBM + CatBoost	5,50 %	+0,01 [−0,01; +0,03]	не отличима, учится вдвое дольше

Что ответить, если спросят. «Три квантильных бустера LightGBM на 26 признаках. Учим не сам поток, а отклонение от нормы: так модель не тратит силы на суточный профиль. LightGBM выбрана, потому что данные табличные, пропуски и категории обрабатываются

нативно. Мы сравнили её с линейной моделью, CatBoost, XGBoost и ансамблем в тех же условиях — лучше никто не оказался».

8. Интервал и калибровка

Простыми словами. Помимо «скорее всего будет 7 178» мы говорим: «с вероятностью 80 % будет от 6 910 до 7 552». Это интервал q_{10} – q_{90} . Хороший интервал честен: если обещает 80 %, то факт попадает в него в 80 % случаев. Сырой интервал модели оказался слишком узким, поэтому мы его «калибруем».

Подробнее.

- **q_{10} – q_{90}** — нижняя и верхняя границы. Между ними должно быть 80 % фактов (покрытие 80 %).
- **Почему сырой интервал узкий.** На обучающих строках модель ошибается меньше, чем на новых. Покрытие сырых квантилей на бэкteste — 73,4 % вместо 80 %.
- **Конформная калибровка (CQR) простыми словами.** Берём модель, которая не видела последние 4 недели обучения, и смотрим, насколько она на них промахивается за границы. Эти промахи — честная оценка того, насколько надо раздвинуть интервал. Нижнюю и верхнюю границы раздвигаем отдельно (поправка асимметричная). Берём чуть более высокий квантиль промахов с поправкой на конечность выборки (множитель $1 + 1/n$), чтобы гарантия не была слишком оптимистичной.
- **Окна внутри обучения.** C — последние 28 суток (калибровка), E — последние 14 суток (ранняя остановка), $E \subset C$. Тест в этих расчётах не участвует.
 1. Отложенная модель учится на обучении без C ; число деревьев — по ранней остановке на E .
 2. Она прогнозирует C , которого не видела; по ошибкам считаются поправки в ячейках «период суток $\times h$ ».
 3. Итоговая модель учится на всём окне.
- **Зачем так сложно.** Ранняя остановка по тесту — подгонка под тест. Калибровка на тех же данных, на которых модель училась, даёт слишком узкий интервал.
- **Станция.** q_{50} станции — сумма q_{50} вестибюлей. Сумма квантилей вестибюлей зависила бы интервал станции: вестибюли не ошибаются в одну сторону одновременно. Поэтому интервал станции — $q_{50} \times$ квантили отношения «факт / q_{50} » по ячейке «группа $\times$ период $\times h$ », посчитанные на прогнозах отложенной модели в окне C .

Наш пример.

- Покрытие на бэкteste: 73,4 % сырое → **80,3 %** после поправки (по фолдам 77,4–82,8 %).
- В сентябре: 67,9 % → **71,7 %**. До 80 % не дотянули: поправка подбиралась на 28.07–24.08, а в сентябре другой уровень (ступенька +13,5 %).
- Pinball, нормированный на средний поток: 1,83 % у модели против 2,27 % у лучшего простого правила.

Что ответить, если спросят. «Сырой интервал покрывал 73 % вместо 80 %. Мы откалибровали его по ошибкам модели, которая не видела последние 4 недели обучения — это конформная поправка. Покрытие стало 80,3 %. В сентябре на сдвиге уровня — 71,7 %: честно записали как ограничение и предложили скользящую калибровку».

9. Честная проверка

Простыми словами. Оценка честна, только если модель проверяют на данных, которые она не видела, и притом в том же порядке, в каком будет жить в реальности: учимся на прошлом, проверяем на будущем. Самый коварный враг — утечка: когда модель случайно «подглядывает» в будущее.

Подробнее — бэктекст.

- **Фолды.** Тестовые месяцы — май, июнь, июль, август. Для каждого модель обучается заново на всей истории до него. Окно расширяется: данных мало, и ранние месяцы терять нельзя.
- **Зазор 7 суток** между обучением и тестом: признаки смотрят назад до 168 часов, и без зазора последние дни обучения и первые дни теста были бы почти одним и тем же.
- **Почему не случайное разбиение (k-fold).** Модель обучалась бы на будущем и проверялась на прошлом, соседние часы одного дня попадали бы и в обучение, и в тест.

Фолд	Обучение (сутки метро)	Тест
май	09.02 – 23.04	01.05 – 31.05
июнь	09.02 – 24.05	01.06 – 30.06
июль	09.02 – 23.06	01.07 – 31.07
август	09.02 – 24.07	01.08 – 31.08
финальный	09.02 – 24.08	01.09 – 29.09, один раз

Почему сентябрь прятали и открыли один раз.

- Сентябрь — единственная по-настоящему невиданная проверка, причём на сдвиге: учебный год и ступенька +13,5 %.
- Без флага `--final` поток сентября превращается в пропуск ещё до расчёта нормы и входов. Так сентябрь не видит ни один код: ни отбор признаков, ни бейзлайны, ни абляция. Тест это проверяет.
- Если подправить модель после теста и перезапустить, тест превращается в ещё один фолд для подгонки.

Заморозка с хэшами.

1. Всё, что определяет модель, записано в `reports/backtest/model_final.json`: признаки, цель, параметры, окна, решение по смеси, правило флага, пороги аномалии без сентября.
2. В файле два вида хэшей SHA-256: конфигурации (2152d675...) и пяти файлов кода (`features.py`, `model.py`, `baseline.py`, `backtest.py`, `eda_spb.py`).
3. Коммит с тегом `freeze-before-final`.
4. Команда `--final` перед запуском пересчитывает хэши и останавливается при расхождении. Повторно тоже не запустится: если файл результатов есть, откажется.
5. До заморозки код теста проверен сухим прогоном на фолде «август».

Как проверяли отсутствие утечки.

- **Обрезка данных.** Поток после конца часа `t` удаляется, панель пересобирается — признаки строк с часом `t` должны совпасть полностью. Проверено в трёх точках: 08.07 09:00 (обычный час), 31.08 08:00 (инцидент), 15.06 04:00 (ночь). Тест чувствителен: если подложить признак из часа `t + 1`, он падает.
- **Нет признаков даты и месяца** — проверяется по именам, типам и связи со временем.

- **Режим повтора:** тест подменяет весь поток после момента прогноза шумом, прогноз не меняется.
- **Калибровка не видит тест:** шум или NaN вместо факта теста ничего не меняют.
- **Однажды нашли свою ошибку:** одноимённый признак затёр колонку, по которой считался бейзлайн. Исправили и запретили совпадение имён тестом.

Как читать результаты проверки:

- **WAPЕ** — суммарная абсолютная ошибка, делённая на суммарный поток. Большие вестибюли в час пик весят больше.
- **Δ WAPЕ** — разница ошибок двух моделей в процентных пунктах (п. п.). Плюс — наша модель лучше.
- **95 % ДИ** — доверительный интервал блочным бутстрепом по дням: «в 95 % перевыборки разница лежит здесь». Если весь интервал выше нуля — выигрыш не случаен.
- **p Диболда–Мариано** — тест, что две модели точны по-разному; учитывает зависимость ошибок соседних часов.

Что ответить, если спросят. «Проверка — бэкtest на четырёх месяцах с расширяющимся окном и неделей зазора, а затем сентябрь, закрытый от любого кода до заморозки. Модель заморожена с хэшами конфигурации и кода, тест запущен один раз, результат записан как есть. Утечку проверяем тестами: если обрезать поток после момента прогноза, признаки не меняются».

Часть 2. После финального теста: стекинг (в продукте) и 15-минутные данные

10. Стекинг (ансамбль): LightGBM + персистентность + GRU

Простыми словами. Представьте трёх прогнозистов и судью. Первый (LightGBM) знает всю историю, но смотрит на данные раз в час. Второй (персистентность) говорит: «следующие полчаса будут такими же необычными, как последние полчаса». Третий (GRU) — нейросеть с памятью: читает поток маленькими 15-минутными шагами за последние 4 часа. Судья (мета-модель) не придумывает свой прогноз, а решает, кому сколько верить, и берёт взвешенное среднее.

Зачем пробовали. Организаторы дали 15-минутные данные, а мы до этого прогнозировали час. Хотелось проверить: если смотреть на поток чаще, получится ли прогноз каждые 30 минут на 4 получасовых слота вперёд (горизонты 30 / 60 / 90 / 120 минут) точнее часового?

Подробнее — постановка.

- Момент прогноза t — hh:00 или hh:30. Слот — получасовой интервал $[t, t+30)$, ..., $[t+90, t+120)$.
- Что известно в момент t : 15-минутные данные до t ; часовые данные — до последнего закрытого часа (в hh:30 час hh ещё не закрыт).
- Истина — сумма двух четвертей 15-минутного источника. Норма слота — $b4 \times s_v \times$ доля половины часа из профиля (поправка источника s_v и профиль — только по прошлому). Цель та же, что у часовой модели: $z = \log((y+1)/(норма+1))$.

Базовые модели (каждая выдаёт q10, q50, q90 в пространстве z):

Модель	Что делает	Что видит
B1 — LightGBM	замороженная часовая модель; её прогноз часа умножается на долю половины часа	всю историю в часовом виде
B2 — персистентность	норма слота $\times$ отклонение последних двух четвертей (30 минут)	последние 30 минут
B3 — GRU	нейросеть: 16 шагов по 15 минут $\rightarrow$ 4 горизонта $\times$ 3 квантиля	последние 4 часа мелким шагом

Что именно делает GRU.

- **GRU** — рекуррентная нейросеть: читает последовательность шаг за шагом и хранит «память» о прочитанном.
- **На каждом шаге** она получает отклонение четверти от нормы, флаг пропуска (ночь, закрытие), отклонение всей линии и флаг пропуска линии. Кроме того, ей даются эмбединги — «лица» вестибюля, четверти суток, дня недели и типа дня.
- **Выход** — 12 чисел: 4 горизонта $\times$ 3 квантиля. Верхняя и нижняя границы заданы как $q50 \pm \text{softplus}$, поэтому квантили не пересекаются.
- **Потери** — pinball, взвешенный нормой слота.
- **Обучение:** 3 seed с усреднением; ранняя остановка по последним 7 суткам обучения; стандартизация по обучению; процессор, один поток, прогнозы воспроизводятся побитово. Последовательности не пересекают разрывы между месяцами: окно допустимо, только если оно целиком лежит внутри своего месяца.

Важно — на чём учится GRU. GRU обучалась на тех же месяцах, что и вся остальная система (февраль, май, июль), просто видит те же данные мелким 15-минутным шагом. Это **не**

«отдельная нейросеть, обученная на 15-минутках сама по себе». Точная схема — расширяющееся окно, как у LightGBM:

Тестовый месяц	Чему учится GRU	Чему учится мета-модель
май	февраль	(вход — прогнозы вне выборки)
июль	февраль + май	(вход — прогнозы вне выборки)
сентябрь	февраль + май + июль	веса заморожены на мае и июле

То есть для каждого тестового месяца GRU видит только предыдущие месяцы, а не «все три сразу».

Почему GRU, а не одномерная свёртка (1D-CNN).

- Окно короткое (16 шагов), скорость не важна.
- Главное в данных — затухание отклонения: оно держится 2–3 часа, последние четверти весят больше всего. Рекуррентное состояние учит это затухание напрямую.
- Ночные и закрытые четверти GRU обходит через флаги и ворота. Свёртка смешивала бы их с данными на тех же позициях.
- На процессоре GRU детерминирована.

Мета-модель — «судья».

- **Вход** — только прогнозы вне выборки за май и июль. Февраль в мета-модель не идёт: часовая LightGBM на нём обучалась, и её прогнозы там чересчур хороши — судья научился бы слишком ей верить.
- **Что подбирает.** Веса базовых моделей для каждого горизонта и каждого квантиля: неотрицательные, в сумме 1; подбор по взвешенному pinball на сетке с шагом 0,05.
- **Сложность выбрана перекрёстно:** «обучить на мае → проверить на июле» и наоборот. Рассматривали веса по горизонту, по горизонту × период суток, по горизонту × минута прогноза (:00 / :30). Ни один вариант не лучший в обоих направлениях, поэтому взят простейший — веса по горизонту. Различия были в пятом знаке pinball.
- **Интервал** — конформная поправка по последнему месяцу обучения стекинга.

Как GRU «сотрудничает» с LightGBM. Модели не сливаются в одну и не обучаются вместе. Каждая отдельно даёт свой прогноз, а судья смешивает: $q = w1 \cdot B1 + w2 \cdot B2 + w3 \cdot B3$ отдельно для q10, q50 и q90 в пространстве z, затем квантили сортируются и калибруются. Если вес одной модели равен 1, стекинг в точности равен ей (это проверяет тест).

Кому судья верит (веса стекинга, обученного на мае и июле):

Квантиль	Модель	30 мин	60 мин	90 мин	120 мин
q10	LightGBM	0,55	0,65	0,70	0,80
q10	персистентность	0,20	0,20	0,20	0,20
q10	GRU	0,25	0,15	0,10	0,00
q50	LightGBM	0,70	0,80	0,90	0,90
q50	персистентность	0,15	0,15	0,10	0,10
q50	GRU	0,15	0,05	0,00	0,00
q90	LightGBM	0,60	0,65	0,65	0,75
q90	персистентность	0,05	0,05	0,05	0,05
q90	GRU	0,35	0,30	0,30	0,20

Читать так: медиану в основном даёт LightGBM, и чем дальше горизонт, тем больше ей верят (0,70 → 0,90). GRU нужна прежде всего для верхней границы вилки: вес у q90 — от 0,20 до 0,35.

Что это дало. Май и июль вместе, всё вне выборки, 185 119 слотов (WAPЕ получасового слота):

Модель	30 мин	60 мин	90 мин	120 мин	Все	Покрытие q10–q90
B1: LightGBM	6,92 %	7,06 %	7,20 %	7,37 %	7,13 %	69,3 %
B2: персистентность	8,72 %	9,04 %	9,40 %	9,76 %	9,22 %	78,3 %
B3: GRU	7,33 %	7,86 %	8,10 %	8,59 %	7,96 %	66,7 %
Простое среднее B1–B3	6,98 %	7,22 %	7,48 %	7,78 %	7,36 %	77,3 %
Стекинг	6,85 %	6,99 %	7,16 %	7,35 %	7,09 %	78,5 %

Выигрыш стекинга у LightGBM (п. п. [95 % ДИ]; лучшая из базовых моделей на каждом горизонте — всегда LightGBM):

	Все слоты	30 мин	120 мин	Аномальные часы
май + июль, основной	+0,05 [+0,02; +0,08]	+0,06 [+0,02; +0,11]	+0,02 [+0,00; +0,03]	+0,56 [+0,37; +0,75]
май (обучен на июле)	+0,04 [–0,00; +0,10]	+0,06 [–0,00; +0,15]	+0,02 [–0,00; +0,04]	+0,79 [+0,44; +1,06]
июль (обучен на мае)	+0,05 [+0,03; +0,08]	+0,06 [+0,01; +0,11]	+0,01 [–0,01; +0,03]	+0,38 [+0,27; +0,50]
сентябрь, один прогон	+0,18 [+0,12; +0,24]	+0,33 [+0,24; +0,43]	+0,06 [+0,03; +0,11]	+0,40 [+0,25; +0,56]

Выводы.

- **Сама по себе GRU слабее:** 7,96 % против 7,13 % у LightGBM. Простое среднее хуже LightGBM (7,36 %): две слабые модели тянут его вниз. Судья нужен, чтобы не усреднять вслепую.
- **В среднем выигрыш почти нулевой:** +0,05 п. п. В часы пик разницы нет (+0,00 [–0,02; +0,03]).
- **Польза только в двух местах:**
 - **аномальные часы:** +0,56 п. п. [+0,37; +0,75] — 15-минутные данные видят отклонение раньше, чем оно доходит до часовой модели;
 - **интервал:** покрытие 78,5 % против 69,3 % у LightGBM на слотах (поправка часовой модели откалибрована на часах, а слот шумнее).
- **Цена для слота «120 минут» в :30.** Прогноз часовой модели, сделанный в hh:00, не доходит до часа hh+2, и мы вызываем её на третий час вперёд (h = 3), хотя учили на h = 1, 2. На первых половинах часа это стоит около 0,3 п. п.: 7,33 % против 7,01 % при h = 2.
- **Сентябрь** (не чистая отложенная выборка — его часовые результаты уже известны): стекинг 8,90 % против 9,08 %, на сдвиге уровня выигрыш втрое больше (+0,18 п. п.). Сильнее всего — на 30 минут из :30: 8,38 % против 8,89 %.

Почему всё-таки включили в продукт — решение команды. `serve.forecast(now)` по умолчанию отдаёт прогноз стекинга, LightGBM — внутри него и запасным путём (`model="lgbm"`).

- **Довод «против».** В среднем выигрыш мал: +0,05 п. п. Перед экспериментом мы сами поставили правило: подключать, только если стекинг лучше LightGBM и на мае, и на июле с ДИ выше нуля. На мае ДИ [–0,00; +0,10] касается нуля — правило не выполнено.
- **Довод «за».** Продукту важна не средняя цифра. Резерв выводят именно в необычные часы, а там стекинг точнее на 0,56 п. п. [+0,37; +0,75]. Интервал честнее: покрытие 78,5 % против 69,3 % у LightGBM. Для решения о резерве важнее не ошибиться в необычный час и честно показать неопределённость, чем выиграть сотые доли процента в среднем.
- **Компромисс.** Команда осознанно отступила от своего правила. Правило не переписали задним числом: результаты записаны как есть, а решение — продуктовое, с открытым обоснованием.

- **Риски:**
 - средний выигрыш может не повториться на новых данных;
 - формат другой: получасовые слоты, горизонты 30–120;
 - стекинг работает только при 15-минутных данных (февраль, май, июль, сентябрь), в 06–00 и в обычные сутки, иначе отвечает LightGBM с пометкой в meta;
 - в мае и июле веса стекинга подобраны на тех же месяцах.
- **Как откатить:** `model="lgbm"`. Решение пересматриваем на новых месяцах данных.

Что ответить, если спросят. «Мы проверили, даёт ли прогноз каждые 30 минут выигрыш. Взяли три базовые модели: часовой LightGBM, персистентность и GRU на 15-минутных рядах — все учились на одних и тех же месяцах. Судья-мета-модель взвешивает их прогнозы: медиану в основном даёт LightGBM, GRU нужна для верхней границы. Итог: GRU сама хуже, стекинг лучше LightGBM всего на 0,05 п. п., и только в аномальных часах (+0,56 п. п.) и по интервалу (78,5 против 69 %) выигрыш заметен. На мае средний выигрыш незначим, и наше же правило не выполнено, но команда включила стекинг ради аномальных часов и честного интервала — это осознанный компромисс, а откат — одна настройка `model="lgbm"`».

11. 15-минутные данные и ранний сигнал

Простыми словами. Часовые данные приходят раз в час. Если в 08:00 что-то случилось, то из часового файла мы узнаем об этом только в 09:00. 15-минутные данные позволяют заметить аномалию уже через полчаса.

Подробнее.

- **Данные.** Февраль, май, июль и сентябрь, 276 480 строк (24 вестибюля × 120 суток × 96 слотов), 75 929 175 входов. Подпись времени та же, что в часовом файле: 00:00–02:45 относятся к следующей дате.
- **Сумма 4 четвертей ≠ часу.** Совпадают точно только 1,7 % часов. 15-минутный источник выше часового на 1,15 % (около +10 входов в час на вестибюль), стабильно по месяцам. **Решение (вариант А):** истина — часовой файл, 15-минутный сигнал делится на поправку источника s_v , посчитанную по 14 прошлым суткам.
- **Профиль внутри часа.** Днём поток почти ровный (неравномерность 5,8 % часа). Резкие часы: открытие (05 ч — 47,9 %), полночь (45,7 %) и утро: в 07 ч поток растёт к концу часа (последняя четверть 31,8 %), в 08 ч убывает.
- **Ранний сигнал.** Частичное отклонение после k четвертей: $r_k = \Sigma \text{факта} / (\text{норма} \times s_v \times \text{доля профиля})$. Экстраполяция $b4 \cdot r_k$ предсказывает весь час.

Наш пример (WAPЕ часа к часовому файлу, февраль + май + июль).

К какой минуте часа	Прогноз	WAPЕ
0 (начало часа)	норма $b4$	7,02 %
0	лучшее простое правило	6,05 %
0	модель $t+1$ (май, июль)	5,15 %
15 минут	экстраполяция $b4 \cdot r1$	7,94 %
30 минут	экстраполяция $b4 \cdot r2$	4,49 %
45 минут	$b4 \cdot r3$	2,76 %

Через 15 минут экстраполяция хуже модели: одна волна поезда в четверти часа весит вчетверо больше, чем в часе. Через 30 минут она уже точнее модели на тех же строках: 4,63 % против 5,15 %, разница $-0,52$ п. п. $[-0,86; -0,23]$.

Детектор тревог. Тревога на первом k , где $|r_k - 1|$ выше порога p_{95} группы, умноженного на s_k ; $s = 1,40 / 1,10 / 1,05$ на 15 / 30 / 45 минут (по максимуму F1 на феврале, мае и июле, зафиксировано до сентября).

К минуте	0	15	30	45	60
Найдено аномальных часов	24 %	43 %	66 %	79 %	92 %
Точность тревог	31 %	35 %	37 %	40 %	42 %
Найдено, сентябрь	55 %	58 %	80 %	89 %	96 %

Зачем это нужно для резерва. Резервный состав выходит на линию за 15–20 минут. По часовым данным аномалия видна только на 60-й минуте часа, по 15-минутным медиана обнаружения — 30 минут: на полчаса раньше. Этого времени хватает, чтобы решение о резерве успело сработать.

Цена ранности — ложные тревоги. Около 60 % ранних тревог ложные: примерно 1,5 на вестибюль в сутки. В сентябре точность выше (72 %), потому что аномалий больше из-за ступеньки уровня.

Что ответить, если спросят. «По часовым данным аномалию видно на 60-й минуте, по 15-минутным — на 30-й: к 30-й минуте находим 66 % аномальных часов. Резерв выходит за 15–20 минут, поэтому эти полчаса важны. Платим ложными тревогами: точность около 40 %, и это отдельный вопрос к рекомендациям».

12. Результаты одной таблицей

	Бэкстест, май–август	Финальный тест, 1–29 сентября
Норма b (4 недели)	7,59 %	11,87 %
Сезонный наивный («как неделю назад»)	10,01 %	8,82 %
Лучшее простое правило «$b \times \text{уровень} \times r(t)$»	6,66 %	9,61 %
LightGBM, финальная	5,51 %	7,72 %
Выигрыш, п. п. [95 % ДИ], p DM	+1,16 [+1,02; +1,30], < 0,001	+1,89 [+1,57; +2,24], < 0,001
Часы пик 07–09 и 17–19: модель / правило	4,50 % / 5,74 %	7,13 % / 9,11 %
Аномальные часы: модель / правило	17,95 % / 16,43 %	13,14 % / 14,16 %
Покрывание интервала q_{10} – q_{90} (цель 80 %)	80,3 %	71,7 %
WAPE по горизонтам $t+1 / t+2$	5,33 % / 5,68 %	7,23 % / 8,21 %

Все цифры — WAPE по всем часам 05–00, среднее по прогнозам на 1 и 2 часа. По фолдам бэктеста: май 6,1 %, июнь 5,6 %, июль 5,2 %, август 5,1 %.

Что показывает таблица:

- Модель лучше простого правила в каждом месяце бэктеста, в часы пик и во всех группах станций.
- Сентябрь труднее (ступенька уровня +13,5 % и новый учебный год): ошибка модели выросла с 5,51 до 7,72 %, но выигрыш у правила вырос с 1,16 до 1,89 п. п.
- Первые две недели сентября — основная ошибка: 9,77 % против 5,84 % во второй половине месяца, когда норма догнала уровень.
- Сильнее всего выигрыш у «прочих» станций: 8,59 % против 12,28 %. Именно у них ступенька выше всех (+28,3 %, учебный год).
- В аномальных часах на бэкteste модель хуже правила — это слабое место (раздел 13).

- Сезонный наивный в сентябре — второй (8,82 %): неделю назад уже был сентябрьский уровень, а норма за 4 недели его не видит.

13. Слабые места честно и что дальше

Слабые места.

Слабость	Цифры	Что про неё сказать
Аномальные часы	на бэкteste 17,95 % у модели против 16,43 % у правила	модель не переносит отклонение целиком вперёд: откат ловит, устойчивый всплеск — хуже
Смесь с правилом	аномальные часы улучшались до 16,96 %, но общий WAPE терял 0,06 п. п. при допуске 0,02	не принята, записана в ограничения
Резкий всплеск: «Алые паруса» 27.06	прогноз линии +14 % к норме, факт +36 %; в таблице особых дней 10,7 % / 12,0 % у модели против 9,6 % / 11,1 % у правила	устойчивый всплеск модель недооценивает
Интервал на сдвиге уровня	в сентябре 71,7 % вместо 80 %	поправка откалибрована на июле–августе
Флаг аномалии шумный	бэкtest: precision 0,33, recall 0,30, F1 0,32; сентябрь: 0,49 / 0,66 / 0,56	флаг предсказывает аномалию за 1–2 часа до неё
Сам провал и отложенный спрос	31.08: провал в 08 ч не предсказан никем; в 10 ч поток +30 % к норме не предсказан	инцидентов такого масштаба в обучении нет
Мало данных	9 месяцев, годовой сезонности нет; праздников в обучении 7, сокращённых дней 3	правило абляции «3 фолда из 4» не видит редкие признаки
Гиперпараметры	не подбирались	один набор параметров и один seed
Только входы	пересадок и направлений нет	оценка ёмкости линии грубая
Два источника потока	15-минутный выше часового на 1,15 %	если живой поток придёт из 15-минутного источника, входы будут на ~1 % выше, чем при обучении
Закрытия входа в пик	Балтийская, Нарвская	часовые флаги их не видят, модель учила их как обычные часы
Нет живого потока	forecast() на сегодня отвечает «вне периода данных»	«сейчас» работает только в режиме повтора

Что дальше.

- **10-минутные данные АСКОП М** — для горизонтов 15–60 минут; контракт уже допускает шаг 15 минут.
- **Скользкая калибровка** интервала по последним 4 неделям перед каждым днём прогноза — закроет недопокрытие на сдвиге.
- **Смесь только для устойчивых отклонений:** вес по длительности отклонения, а не по величине.
- **Особые дни:** вернуть группу признаков, когда в обучении будет не меньше 4 сокращённых дней (следующий — 3.11).
- **Стекинг на большем объёме данных:** в сентябре его выигрыш +0,18 п. п., втрое больше, чем на мае и июле; решение о включении пересмотреть на новых месяцах — если выигрыш исчезнет и в аномальных часах, откатить на LightGBM. Кандидаты в базовые модели — LightGBM на 15-минутных признаках и часовая модель, обученная на третьем часе вперёд.
- **Ансамбль LightGBM + CatBoost:** в сентябре на 0,04 п. п. лучше LightGBM ($p = 0,056$); проверить на новых месяцах.

- **Подбор гиперпараметров** на отложенном окне.

Что ответить, если спросят. «Главное слабое место — аномальные часы: модель хуже простого правила на 1,5 п. п., потому что не переносит отклонение целиком. Мы пробовали смесь, но она портила общую точность. Второе — интервал на сдвиге уровня: 72 % вместо 80 %. Всё это записано в ограничения, есть план: скользящая калибровка и более частые данные».

14. Демо 31.08 по шагам

Простыми словами. 31 августа на «Чернышевской» была остановка обслуживания с 07:50 до 10:31. Поток по всей линии обвалился, а потом откатился назад. Мы показываем, как две модели прогнозируют следующий час в 08:59, когда провал уже виден, а откат ещё нет.

Шаг за шагом.

1. **Что произошло.** На «Девяткино» в 08 ч вошло 3 969 человек при норме 13 942. Поток упал не только там, где закрывали вход: Девяткино II — 0,21 от нормы, Девяткино I — 0,40, пл. Ленина-1 — 0,62, Чернышевская — 0,64.
2. **Момент прогноза — 08:59.** Данные до конца 08 ч известны. В последний час поток на «Девяткино» на 75 % ниже нормы, вся линия на 25 % ниже нормы. Прогнозируем 09 ч (горизонт 60) и 10 ч (горизонт 120).
3. **Что говорит простое правило** «норма × текущее отклонение»: проваленный час повторится. На «Девяткино» на 09 ч — 2 849 при норме 8 295.
4. **Что говорит модель.** Модель `lgbm_holdout` (обучена по 24.08, то есть вне выборки) отвечает 7 178 [6 910; 7 552].
5. **Что было на самом деле:** 8 445. Поток вернулся к норме.
6. **Почему модель права.** Она выучила: крайнее отклонение последнего часа вместе с провалом всей линии не держится. В обучении 31.08 и похожих провалов не было — это не заучивание, а общая закономерность. Топ-3 причины: «в последний час поток на 75 % ниже нормы» (−7 %), «вся линия на 25 % ниже нормы» (−5 %), «поправка на величину нормы» (−3 %).

Наш пример — 09:00, горизонт 60 минут, прогноз в 08:59:

Станция	Норма	Простое правило	Модель [q10; q90]	Факт
Девяткино	8 295	2 849	7 178 [6 910; 7 552]	8 445
Площадь Ленина	2 299	1 605	1 960 [1 824; 2 126]	2 750
Чернышевская	846	538	758 [705; 822]	694
Нарвская	957	2 577	1 072 [1 000; 1 147]	1 099
вся линия	39 428	34 237	38 081	42 467

На 10 ч (горизонт 120) у «Девяткино»: норма 5 079, правило 1 718, модель 4 421, факт 6 594; по всей линии — норма 29 470, правило 26 151, модель 28 581, факт 33 019.

Что честно признать:

- **Сам провал в 08 ч не предсказывает никто:** прогноз на 08 ч сделан до инцидента, и обе модели дают норму.
- **Факт 8 445 выше интервала модели** [6 910; 7 552]. Модель откатывается к норме, но откат вышел сильнее.
- **Отложенный спрос выше нормы** (10 ч, +30 %) модель не предсказала: подобных случаев в обучении не было.

- **Нарвская** — обратный случай: в 08 ч $\times 2,7$ к норме, правило переносит пик (2 577), модель нет (1 072 при факте 1 099). Но этот пик в основном конец режима закрытия входа 08:15–09:00, а не уход пассажиров с других станций.
- **Флаг аномалии** стоял на всех станциях инцидента — это сигнал диспетчеру ещё до сообщения об остановке.

Про две версии цифр. В docs/backtest.md демо посчитано моделью фолда «август» (обучена до 24.07): «Девяткино» 09 ч — 7 545. В режиме повтора (команда `python -m src.serve --now "2026-08-31 08:59"`) отвечает `lgbm_holdout: 7 178`. Это одна и та же конфигурация модели, обученная на разной длине истории; везде выше — режим повтора. Стекинг для 31.08 не отвечает: за август нет 15-минутных данных, поэтому `serve` автоматически отдаёт часовую LightGBM и пишет причину в `meta["fallback"]`.

Что ответить, если спросят. «31.08 на „Девяткино“ в 08 ч вошло 3 969 при норме 13 942. В 08:59 мы прогнозируем 09 ч: простое правило переносит провал вперёд и даёт 2 849, наша модель — 7 178 при факте 8 445. Модель поняла, что такой провал не держится: училась без этого дня. Сам провал в 08 ч не предсказывает никто, и откат вышел чуть выше нашего интервала — это мы честно показываем».

Часть 3. 50 вопросов жюри и короткие ответы

15. Вопросы и ответы

Данные

1. Откуда у вас данные? Организаторы передали почасовые входы по 23 вестибюлям 1 линии за 01.01–30.09.2026 (150 144 строки, 164 876 717 входов) и 15-минутные данные за четыре месяца. Мы добавили календарь (isdayoff.ru), погоду (Open-Meteo) и справочник событий.

2. Зачем вы использовали открытые данные другого метро? Пока реальных данных не было, мы на них отладили загрузку, очистку, контракт, разведочный анализ и правила для признаков. Обучение модели и все её цифры — только по СПб.

3. Хватает ли 9 месяцев данных? Для часового прогноза с нормой по 4 неделям — да: бэк-тест на четырёх фолдах даёт 5,51 %. Но годовой сезонности нет, праздников в обучении 7, сокращённых дней 3: это записано в ограничения.

4. Какие ловушки нашли в данных? Дата в виде текста с неверным порядком строк; часы 00–02 подписаны датой прошедших суток; режимы закрытия вестибюлей; инцидент 31.08; особые ночи; частичные закрытия входа в пик на Балтийской и Нарвской; расхождение двух источников на 1,15 %. Каждую нашли проверкой и учли флагом или поправкой.

5. Как вы поняли, что часы 00–02 сдвинуты? Три признака: вход в 00 ч выше всего у меток пятницы и субботы (1 736 и 1 887 против 976–1 180); аномалия «D 00» связана с «D 23» на 0,76 и с «D–1 23» на 0,35; ночь «Алых парусов» непрерывна только при сдвиге. После исправления всё пересчитано.

6. Почему вы исключаете часы с флагами? Ноль в закрытый час — это расписание, а не спрос; провал при инциденте научил бы модель, что такое бывает в обычный понедельник. Исключаются только цели и метрики, а входы (наблюдённый поток) берутся как есть, включая час инцидента: в момент прогноза это реальные данные. Из 125 120 строк в часы работы метро исключено 1 730, то есть 1,4 %.

7. Что такое «сутки метро»? Сутки с 05:00 до 04:59 следующего дня. Час 00 относится к прошедшим суткам. Так устроена выгрузка, и так считаются нормы и «вчера».

8. Почему только входы? В данных нет выходов, пересадок и направлений. Поэтому оценка ёмкости линии грубая: нагрузка самого загруженного перегона не равна сумме входов.

9. Что с «Технологическим институтом»? В часовых данных его нет, в 15-минутных есть (около 10 тыс. входов в сутки). Модель его не прогнозирует; в профиль внутри часа он включён.

Модель

10. Что такое норма и почему медиана? Норма — медиана того же вестибюля, часа и дня недели по 4 последним обычным таким же дням. Медиана устойчива к необычным дням (закрытие, дождь), среднее — нет. Для праздников берётся профиль воскресенья.

11. Почему вы предсказываете отклонение от нормы, а не сам поток? Так модель не тратит силы на суточный профиль и на разницу масштабов вестибюлей, а учит только «насколько сегодня не как обычно». Цель «отношение к норме» лучше, чем $\log(1 + y)$: 5,49 % против 5,76 %.

12. Почему LightGBM? Данные табличные, нужные зависимости — взаимодействия (час × вестибюль × текущее отклонение); LightGBM сам работает с пропусками и категориями и учится

за секунды. Сравнение в тех же условиях: линейная модель 5,70 %, CatBoost 5,56 %, XGBoost 5,61 %, ансамбль 5,50 % против 5,51 % у LightGBM.

13. Что такое q10, q50, q90 и зачем три модели? Три квантиля распределения прогноза: q50 — медиана, [q10; q90] — интервал на 80 %. У каждого своя функция потерь pinball: при $\alpha = 0,9$ недооценка штрафует в 9 раз сильнее переоценки. Распределение несимметрично, поэтому «среднее $\pm$ разброс» не подходит.

14. Зачем веса строк? Метрика WAPE взвешена потоком: ошибка в час пик на большом вестибюле важнее, чем ночью на малом. Без весов малые вестибюли и крайние часы (05, 23, 00) тянули бы модель на себя. Вес — норма f_{ref} .

15. Какие признаки главные? По важности: отклонение всей линии — 17 %, отклонение в тот же час вчера — 13 %, отклонение последнего часа — 12 %, вестибюль — 9 %, норма — 8 %, уровень — 5 %. Без группы «кросс» модель теряет 0,13 п. п., без «вчера» — 0,14.

16. Почему нет признаков даты и месяца? В тестовом месяце они принимают значения, которых модель не видела, и дерево ведёт себя непредсказуемо. Отсутствие таких признаков проверяет тест.

17. Что такое конформная калибровка? Модель, которая не видела последние 4 недели обучения, прогнозирует их; по её промахам за границы q10 и q90 считаем, насколько раздвинуть интервал (отдельно вниз и вверх). Покрытие стало 80,3 % вместо 73,4 %.

18. Почему погода почти ничего не добавляет? Дождь снижает вход всего на 4,5 %, это меньше разброса слота ($\pm 11,4$ %). В абляции погода прошла на грани: +0,03 п. п. [+0,01; +0,05]. Оставили как устойчивый, хотя слабый сигнал.

19. Как получаются «три причины» прогноза? Предсказание деревьев раскладывается на вклады признаков (значения SHAP для деревьев). Берутся три самых больших по модулю, текст строится по значению признака: «в последний час поток на 75 % ниже нормы». Сумма вкладов равна прогнозу — это проверяет тест.

20. Почему модель работает на вестибюлях, а не на станциях? Вестибюли одной станции работают в разном режиме (пл. Ленина-2 закрывается в 22 ч, Ленинский пр.-2 работает 06–21), и при инциденте поток перетекает между ними. Суммирование до станции стёрло бы это. В контракт q50 станции — сумма q50 вестибюлей, интервал станции калибруется отдельно.

21. Зачем два горизонта и чем они отличаются? Прогнозируем 1 и 2 часа: WAPE 5,33 % и 5,68 %. Отклонение затухает, поэтому на втором часе выигрыш от динамики примерно в 1,4 раза меньше.

Проверка

22. Почему WAPE? Это суммарная абсолютная ошибка медианного прогноза, делённая на суммарный поток. Ошибка на Девяткино II в час пик весит больше, чем на малом вестибюле ночью, — так и нужно для планирования составов.

23. Что такое фолд и зачем зазор? Фолд — одно разбиение «обучение — тест»; у нас 4 (май–август) с расширяющимся окном. Зазор 7 суток нужен потому, что признаки смотрят назад до 168 часов: без зазора последние дни обучения и первые дни теста были бы почти одинаковыми.

24. Почему не случайное разбиение? Модель обучалась бы на будущем и проверялась на прошлом, а соседние часы одного дня попадали бы и в обучение, и в тест. Для временных рядов это утечка.

25. Что такое утечка и как вы её проверяли? Утечка — когда признак использует то, чего нет в момент прогноза. Проверка: удаляем поток после конца часа t , пересобираем признаки — они должны совпасть (три точки: 08.07 09:00, 31.08 08:00, 15.06 04:00). Тест падает, если подложить признак из часа $t + 1$. Режим повтора проверен подменой будущего шумом.

26. Зачем заморозка с хэшами? Чтобы нельзя было подправить модель после финального теста. В `model_final.json` записаны конфигурация (хэш 2152d675...) и хэши пяти файлов кода, поставлен `freeze-before-final`. Команда теста сверяет хэши и повторно не запускается.

27. Как читать ΔWAP , ДИ и p Диболда–Мариано? ΔWAP — разница ошибок в процентных пунктах, плюс означает, что наша модель лучше. ДИ — интервал блочным бутстрепом по дням: если он весь выше нуля, выигрыш не случаен. p DM — тест, что модели точны по-разному, с учётом зависимости ошибок.

28. Что такое абляция? Проверка пользы частей модели: группы признаков добавляем по одной и смотрим на ошибку. Группа остаётся, если средний выигрыш > 0 и он положителен минимум в 3 фолдах из 4.

29. Почему в сентябре ошибка 7,72 %, а не 5,51 %? Это провал? Нет, сентябрь труднее: ступенька уровня +13,5 % и новый учебный год, норма за 4 недели отстаёт. В первую половину сентября ошибка 9,77 %, во вторую, когда норма догнала уровень, — 5,84 %. Выигрыш у лучшего правила при этом вырос: с 1,16 до 1,89 п. п.

30. Сколько раз вы смотрели на сентябрь? Финальный тест — один раз (повторный запуск команда не разрешает). Потом сентябрь использовался «для информации»: сравнение моделей (один прогон), ранний сигнал по 15-минутным данным и стекинг — везде с пометкой, что часовые результаты по сентябрю уже известны.

31. Что значит «вне выборки»? Прогноз сделан моделью, обученной раньше предсказываемого периода с зазором в 7 суток. Например, для мая — `lgbm_fold_2026-05`, обучена по 23.04. В режиме повтора это видно в `meta.out_of_sample`.

Продукт

32. Как команда получает прогноз? По общему контракту: `records` (`q10`, `q50`, `q90`, `baseline`, `is_anomaly`), `explanations` (три причины) и `meta`. Схема — `pydantic` и `JSON Schema` для любого языка. Вызов `serve.forecast(now)` по умолчанию отвечает стекингом: 18 станций $\times$ 4 получасовых слота, горизонты 30–120 мин, около 3 секунд. Где 15-минутных данных нет, отвечает часовая `LightGBM` — 18 станций $\times$ 2 горизонта (60 и 120 мин) — и пишет причину в `meta["fallback"]`.

33. Что такое флаг аномалии и почему он слабый? Флаг — $|q50 / \text{норма} - 1|$ выше порога `r80` группы и периода суток. На бэкteste `precision` 0,33, `recall` 0,30, `F1` 0,32; в сентябре 0,49 / 0,66 / 0,56. Слабый, потому что предсказывает аномалию за 1–2 часа до неё: провал 31.08 в 08 ч в 07 ч не виден никому.

34. Что такое режим повтора? Прогноз на любой исторический момент «как будто сейчас»: данные после этого момента не используются (проверено подменой шумом). Модель выбирается по дате: самая свежая из обученных не позже чем за 7 суток до момента.

35. Есть ли живой поток? Нет. Поток в данных заканчивается 29.09; `forecast()` на сегодня отвечает «вне периода данных». Ветка Яндекс Погоды в «боевом» режиме заработает вместе с живым потоком.

36. Что LLM-слой берёт у вас? Три причины прогноза словами. Контекст поездов и событий идёт отдельно в `explanations[ ].context`; модель события и поезда не использует, потому что не обучена на них.

37. Что такое baseline в контракте? Норма: сумма b4 вестибюлей станции. Флаг аномалии сравнивает с ней q50.

38. Что передано команде? Контракт и заглушка, прогнозы на август (22 320 записей), режим повтора со стекингом по умолчанию, документация, графики, профиль внутри часа `intrahour_profile.csv` для симулятора. Код и веса смешивания — в ветке `main` репозитория команды. Веса базовых моделей (`models/`, около 21 МБ) и данные в `git` не хранятся: их передаём архивом или собираем командами. Как получить ансамбль у себя — в README, раздел «Как получить ансамбль у себя без переобучения».

39. Что дальше для продукта? Живой поток, 10-минутные данные, скользящая калибровка интервала и решение роли 4: нужен ли ранний детектор при примерно 1,5 ложной тревоге на вестибюль в сутки.

Каверзные вопросы

40. Почему не нейросеть? Данных 9 месяцев; данные табличные; ТЗ сознательно исключало нейросети. Бустинг ловит взаимодействия, обрабатывает пропуски и категории и обучается за секунды. Когда мы всё же проверили GRU, она сама оказалась слабее: 7,96 % против 7,13 % у LightGBM.

41. Что дала нейросеть? Сама по себе — ничего: хуже LightGBM. В ансамбле даёт пользу в двух местах: аномальные часы (+0,56 п. п. [+0,37; +0,75]) и интервал (покрытие 78,5 % против 69,3 %). В среднем выигрыш всего +0,05 п. п.

42. Как нейросеть работает с бустингом? Модели не сливаются: каждая даёт свой прогноз, а мета-модель-судья берёт их взвешенно по каждому горизонту и квантилю. В медиане LightGBM весит 0,70–0,90, GRU — 0–0,15; для верхней границы q90 GRU весит 0,20–0,35. Если вес одной модели равен 1, ансамбль в точности равен ей.

43. Нейросеть учили отдельно на 15-минутках? Нет. Она учится на тех же месяцах (февраль, май, июль), что и вся система, и видит те же данные, но мелким 15-минутным шагом за последние 4 часа. Окно расширяется: для мая — февраль, для июля — февраль + май, для сентября — февраль + май + июль.

44. Откуда вы знаете, что не подогнали? Сентябрь закрыт от любого кода до заморозки; модель заморожена с хэшами и протестирована один раз; бэктест идёт вперёд по времени с зазором; тесты проверяют утечку; гиперпараметры не подбирались; отбор признаков видел только апрель–август. Честная оговорка: разведочный анализ видел и тестовые месяцы, но использовался только для разметки срезов, а не для обучения.

45. Что если данные врут? Мы это проверяли: контрольные суммы сходятся ($164\,876\,717 + 418 = 164\,877\,135$), даты проверены правилом «08 ч / 12 ч», сдвиг часов найден и исправлен, 31 час с расхождением источников исключён из оценки. Модель использует медианную норму, устойчивую к необычным дням. Открытый вопрос к организаторам — какой источник пойдёт в живой поток: 15-минутный выше часового на 1,15 %.

46. Зачем вы включили стекинг, если ваше же правило на мае не выполнено? Это решение команды, и мы его не прячем. Правило, поставленное заранее (лучше LightGBM и на мае, и на июле), на мае не выполнено: ДИ [–0,00; +0,10]. Но в аномальных часах, где решается вопрос о резерве, стекинг точнее на 0,56 п. п. [+0,37; +0,75], а интервал честнее (78,5 % про-

тив 69,3 %). Для продукта это важнее средней цифры. Результаты записаны как есть, риски названы, откат — `model="lgbm"`.

47. Выигрыш 0,05 п. п. — это вообще что-то? Статистически значим (+0,05 [+0,02; +0,08] на мае и июле), но на практике почти незаметен. Реальная польза — в аномальных часах (+0,56 п. п.) и в честности интервала: ради них команда и включила стекинг. На сдвиге уровня в сентябре выигрыш втрое больше (+0,18 п. п.).

48. Что будет, если завтра случится инцидент? Сам провал мы не предскажем: прогноз сделан до инцидента и даёт норму. Но откат модель ловит: 31.08 на «Девяткино» на 09 ч она дала 7 178 при факте 8 445, а простое правило — 2 849. Флаг аномалии стоял на всех станциях инцидента.

49. Почему модель хуже простого правила в аномальных часах? На бэкteste 17,95 % против 16,43 %. Модель выучила, что крайнее отклонение откатывается (как 31.08), и поэтому недооценивает устойчивый всплеск («Алые паруса»). Смесь с правилом улучшала аномальные часы до 16,96 %, но общий WAPE терял 0,06 п. п. при допуске 0,02 — не принята. В сентябре на сдвиге модель уже не хуже правила: 13,14 % против 14,16 %.

50. Что считать успехом, если ошибка 5,5 %? Шум одного слота вокруг нормы — p50 5,0 % и p80 11,4 %, поэтому ошибка в 5,5 % того же порядка, что случайный разброс. Цель — не ноль, а быть лучше простых правил (+1,16 и +1,89 п. п., $p < 0,001$) и давать честный интервал. На сентябре, где данные сдвинулись, выигрыш даже вырос.

Сценарий презентации на 5 минут

Формат. 9 слайдов. У каждого слайда: заголовок, крупные пункты (3–5), картинка из reports/figures/ и текст «что говорить вслух». Весь текст вслух — около 650 слов, примерно 5 минут при спокойном темпе. Ключевой слайд — седьмой, демо 31.08: на него уходит минута.

№	Слайд	Время
1	Прогноз входов на станции метро	20 с
2	Проблема: резерв выходит за 15–20 минут	30 с
3	Данные и ловушки	35 с
4	Главная идея: отклонение держится 2–3 часа	35 с
5	Как работает модель	40 с
6	Честная проверка	35 с
7	Результат и демо 31.08	60 с
8	Слабые места и что дальше	30 с
9	Итог	15 с
	Всего	5 мин

Если времени мало: слайды 2 и 6 можно сократить до одной фразы, слайд 7 не сокращать.

Слайд 1. Прогноз входов на станции метро на 1–2 часа вперёд

На слайде:

- 1 линия метро СПб, 18 станций;
- прогноз каждые 30 минут (стекинг, по умолчанию в продукте) и каждый час (часовая модель): медиана и интервал q10 / q50 / q90, норма, флаг аномалии, три причины;
- ML стоит в начале цепочки: симулятор → рекомендации → дашборд.

Картинка: docs/report/figures/fig_system.png — схема системы.




Говорить вслух (20 с). Мы прогнозируем, сколько людей войдёт на каждую станцию первой линии в ближайшие один и два часа. Прогноз получает симулятор загрузки, потом рекомендации по составам и дашборд, так что от его точности зависит вся цепочка.

Слайд 2. Проблема: резерв выходит за 15–20 минут

На слайде:

- резервный состав выходит на линию за 15–20 минут;
- полный оборот — 99 минут, в резерве 4 состава, парность до 32 пар в час;
- нужно знать поток заранее: на 1–2 часа вперёд;
- дальше смотреть не имеет смысла: отклонение от нормы живёт 2–3 часа.

Картинка: reports/figures/spb_01_profiles.png — суточные профили: у спальных станций утренний пик, у центра вечерний.




Говорить вслух (30 с). Резервный состав выходит на линию за 15–20 минут, полный оборот занимает 99 минут, в резерве четыре состава. Чтобы вовремя добавить поезда, нужно знать поток заранее. Поэтому горизонт — один и два часа: короче поздно, а длиннее прогноз теряет ценность, потому что отклонение от нормы живёт два–три часа.

Слайд 3. Данные и ловушки

На слайде:

- 23 вестибюля × 6 528 ч = 150 144 строки, 164 876 717 входов;
- ловушка 1: даты — текст, строки в перепутанном порядке;
- ловушка 2: часы 00–02 подписаны датой прошедших суток (доказали тремя признаками);
- ловушка 3: режимы закрытия вестибюлей, инцидент 31.08, закрытия входа в пик.

Картинка: reports/figures/spb_07_incident.png — инцидент 31.08 по вестибюлям.




Говорить вслух (35 с). Организаторы дали почасовые входы по 23 вестибюлям за девять месяцев; пока их не было, мы отладили конвейер на открытых данных метро другого города. В реальных данных были ловушки: даты шли текстом в перепутанном порядке; часы с полуночи до двух подписаны датой прошедших суток, и мы доказали это тремя независимыми признаками; вестибюли закрываются по режиму; плюс инцидент 31 августа. Каждую ловушку учли флагом и всё пересчитали.

Слайд 4. Главная идея: отклонение от нормы держится 2–3 часа

На слайде:

- норма — «сколько обычно в этот час»; отклонение $r = \text{факт} / \text{норма}$;
- корреляция отклонения с лагом 1 / 2 / 3 часа: 0,72 / 0,59 / 0,44;
- после часа с $r > 1,15$ такое же отклонение остаётся в 50 % следующих часов (в среднем — 11 %);
- «норма × текущее отклонение»: ошибка 8,53 → 6,74 %.

Картинка: reports/figures/spb_08_persistence.png — три панели: лаги, распределение после $r > 1,15$, связь утра с вечером.




Говорить вслух (35 с). Главная идея простая: если в этот час людей больше обычного, то и в ближайшие два-три часа их будет больше. Корреляция с лагом в час — 0,72, в три часа — 0,44. После часа с отклонением больше 15 % такое же отклонение остаётся в половине следующих часов, а в среднем — только в 11 %. Даже простое правило «норма на текущее отклонение» снижает ошибку с 8,5 до 6,7 %.

Слайд 5. Как работает модель

На слайде:

- норма = медиана того же часа за 4 последних таких же дня × поправка на уровень недели;
- модель учит отклонение от нормы, а не сам поток;
- три LightGBM: q10, q50, q90; 26 признаков: последний час, вся линия, соседи, вчера, дождь;
- интервал калибруем: покрытие 73,4 % → 80,3 %.

Картинка: docs/report/figures/fig_calibration.png — покрытие интервала до и после поправки.




Говорить вслух (40 с). Норма — медиана того же часа за четыре последних таких же дня с поправкой на уровень недели. Модель учит не сам поток, а отклонение от нормы. Три модели LightGBM дают нижнюю границу, медиану и верхнюю границу; на входе 26 признаков: последний час, вся линия, соседи, вчера и дождь. Сырой интервал был узким — покрывал 73 % вместо 80. Конформная калибровка подняла покрытие до 80,3 %.

Слайд 6. Честная проверка

На слайде:

- бэктест на 4 месяцах: расширяющееся окно, зазор 7 суток;
- сентябрь закрыт от любого кода, открыт один раз;
- заморозка: хэши конфигурации и кода, тег `freeze-before-final`;
- тесты на утечку: поток после момента прогноза не меняет признаки.

Картинка: docs/report/figures/fig_folds.png — фолды, зазор и закрытый сентябрь.



Говорить вслух (35 с). Проверка идёт вперёд по времени: четыре месяца с расширяющимся окном и недель зазора. Сентябрь был закрыт от любого кода. Модель заморозили с хэшами конфигурации и кода, поставили тег — и только потом запустили тест, ровно один раз. Утечку проверяют тесты: если обрезать поток после момента прогноза, признаки не меняются.


Слайд 7. Результат и демо 31.08 (ключевой)

На слайде:

- **31.08:** на Девяткино в 08 ч вошло 3 969 при норме 13 942 (инцидент на «Чернышевской»);
- прогноз на 09 ч в 08:59: простое правило — 2 849, **модель — 7 545**, факт — 8 445, норма — 8 295;
- модель поняла, что такой провал не держится; сам провал не предсказывает никто;
- итог: 5,51 против 6,66 % (бэкtest) и 7,72 против 9,61 % (закрытый сентябрь).

Картинка: reports/figures/spb_15_demo_0831.png — станция Девяткино, прогнозы на 1 и 2 часа; оранжевая линия — простое правило, синяя — модель. Вторая картинка — лестница WAPE spb_14_wape_ladder.png.

Демо-кейс 31.08: провал из-за инцидента и откат спроса, Девяткино
прогнозы model_aug.json и baseline_aug.json: обучение до 24.07, вне выборки



Говорить вслух (60 с). Ключевой пример — 31 августа. На «Девяткино» в восемь утра из-за остановки на «Чернышевской» вошло 3 969 человек при норме почти 14 тысяч. В 08:59 мы прогнозируем девять часов. Простое правило переносит провал вперёд: 2 849. Наша модель, обученная до 24 июля, то есть не видевшая этот день, даёт 7 545 при факте 8 445. Она выучила, что такой провал вместе с провалом всей линии не держится. Сам провал в восемь часов не предсказывает никто, и откат вышел выше нашего интервала — это мы честно показываем. Итог по метрикам: 5,51 процента против 6,66 на бэкtestе и 7,72 против 9,61 в закрытом сентябре.

Примечание для себя. График построен моделью фолда «август» (обучена до 24.07): 7 545. В режиме повтора (python -m src.serve --now "2026-08-31 08:59") отвечает lgbm_holdout (обучена по 24.08): 7 178 [6 910; 7 552]. Если жюри спросит про расхождение

— это одна конфигурация на разной длине истории; правило и факт те же. Стекинг для 31.08 не отвечает: за август нет 15-минутных данных, и `serve` сам отдаёт часовую LightGBM.


Слайд 8. Слабые места и что дальше

На слайде:

- аномальные часы: 17,95 % у модели против 16,43 % у простого правила;
- интервал в сентябре покрыл 71,7 % вместо 80 %; флаг тревог шумный (F1 0,32 на бэкте-сте);
- стекинг с нейросетью GRU включили в продукт: в среднем +0,05 п. п. (на мае незначимо), но в аномальных часах +0,56 п. п. и интервал честнее (78,5 % против 69 %) — осознанный компромисс;
- дальше: 10-минутные данные, скользящая калибровка, стекинг на большем объёме дан-ных.

Картинка: `reports/figures/spb_17_wape_horizon.png` — WAPE получасовых прогно-зов: стекинг против частей.

Прогноз каждые 30 минут: точность по горизонтам



Говорить вслух (30 с). Слабые места мы измерили. В аномальных часах модель хуже простого правила: 17,95 процента против 16,43. Интервал на сдвиге уровня в сентябре покрыл 72 процента вместо 80. Флаг тревог шумный. Ещё мы проверили ансамбль с нейросетью: в среднем он лучше всего на 0,05 пункта, но в аномальных часах — на 0,56, и интервал честнее. Поэтому команда включила его в продукт, хотя наше же правило на мае не выполнено, — это осознанный компромисс. Дальше — десятиминутные данные и скользящая калибровка.

Слайд 9. Итог

На слайде:

- модель точнее лучшего простого правила на 1,16 п. п. (бэкстест) и 1,89 п. п. (сентябрь), $p < 0,001$;
- проверка честная: сентябрь закрыт, модель заморожена, тест один раз;
- слабые места известны и измерены;
- результат передан команде по общему контракту: код — в `main`, веса моделей — архивом, инструкция — в `README`.

Картинка: не нужна — оставить на экране таблицу с главными цифрами.

Говорить вслух (15 с). Итог: модель точнее лучшего простого правила на 1,16 и на 1,89 процентного пункта, проверена честно и заморожена, а слабые места известны и измерены. Готовы к вопросам.